

**PEMBOBOTAN ATRIBUT PADA METODE *SIMPLE ADDITIVE  
WEIGHTING (SAW)* MENGGUNAKAN *GAIN RATIO* DALAM  
SISTEM PENDUKUNG KEPUTUSAN**

**TESIS**

**ADE RIZKA**

**167038034**



**PROGRAM STUDI S2 TEKNIK INFORMATIKA  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA  
MEDAN  
2018**

**PEMBOBOTAN ATRIBUT PADA METODE *SIMPLE ADDITIVE  
WEIGHTING (SAW)* MENGGUNAKAN *GAIN RATIO* DALAM  
SISTEM PENDUKUNG KEPUTUSAN**

**TESIS**

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh  
ijazah Magister Teknik Informatika

**ADE RIZKA**  
**167038034**



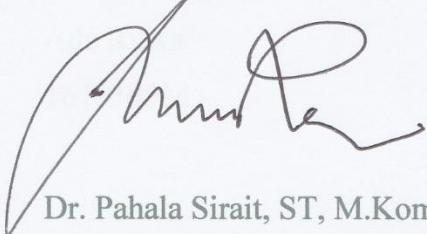
**PROGRAM STUDI S2 TEKNIK INFORMATIKA  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA  
MEDAN  
2018**

## PERSETUJUAN

Judul : PEMBOBOTAN ATRIBUT PADA METODE *SIMPLE ADDITIVE WEIGHTING (SAW)* MENGGUNAKAN *GAIN RATIO* DALAM SISTEM PENDUKUNG KEPUTUSAN  
 Kategori : TESIS  
 Nama : ADE RIZKA  
 Nomor Induk Mahasiswa : 167038034  
 Program Studi : MAGISTER (S-2) TEKNIK INFORMATIKA  
 Fakultas : ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
                   UNIVERSITAS SUMATERA UTARA

Komisi Pembimbing :

Pembimbing 2



Dr. Pahala Sirait, ST, M.Kom

Pembimbing 1



Dr. Syahril Efendi, S.Si, M.IT

Diketahui/disetujui oleh

Program Studi Magister (S2) Teknik Informatika

Ketua,



Prof. Dr. Muhammad Zarlis

NIP. 19570701 198601 1 003

## **PERNYATAAN**

### **PEMBOBOTAN ATRIBUT PADA METODE *SIMPLE ADDITIVE WEIGHTING* (SAW) MENGGUNAKAN *GAIN RATIO* DALAM SISTEM PENDUKUNG KEPUTUSAN**

#### **TESIS**

Saya mengakui bahwa tesis ini adalah hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 23 Juli 2018

Ade Rizka

167038034

**PERNYATAAN PERSETUJUAN PUBLIKASI  
KARYA ILMIAH UNTUK KEPENTINGAN  
AKADEMIS**

Sebagai sivitas akademika Universitas Sumatera Utara, saya yang bertanda tangan dibawah ini :

Nama : Ade Rizka  
Nim : 167038034  
Program Studi : Magister (S-2) Teknik Informatika  
Jenis Karya Ilmiah : Tesis

Demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Sumatera Utara Hak Bebas Royalti Non-Eksklusif (*Non-Exclusive Royalty Free Right*) atas tesis saya yang berjudul :

**PEMBOBOTAN ATRIBUT PADA METODE *SIMPLE ADDITIVE WEIGHTING*  
(SAW) MENGGUNAKAN *GAIN RATIO* DALAM SISTEM PENDUKUNG  
KEPUTUSAN**

Beserta perangkat yang ada (*jika diperlukan*). Dengan Hak Bebas Royalti Non-Eksklusif ini, Universitas Sumatera Utara berhak menyimpan, mengalih media, memformat, mengelola dalam bentuk database, merawat dan mempublikasikan tesis saya tanpa meminta izin dari saya selama tetap mencantumkan nama saya sebagai penulis dan sebagai pemegang dan/atau sebagai pemilik hak cipta.

Demikian pernyataan ini dibuat dengan sebenarnya.

Medan, 23 Juli 2018

Ade Rizka

167038034

Telah diuji pada

Tanggal : 23 Juli 2018

---

**PANITIA PENGUJI TESIS**

Ketua : Dr. Syahril Efendi, S.Si, M.IT

Anggota : 1. Dr. Pahala Sirait, ST, M.Kom

2. Prof. Dr. Muhammad Zarlis

3. Dr. Maya Silvi Lydia

## **RIWAYAT HIDUP**

### **DATA PRIBADI**

Nama Lengkap (berikut gelar) : Ade Rizka, S.Kom  
Tempat dan Tanggal Lahir : Medan, 9 Juni 1993  
Alamat Rumah : Jl. Eka Rasmi Jl. Pipa Air Bersih No. 7 Gedung Johor, Medan  
Telepon/HP : 08116096693  
Email : aderizka33@yahoo.com

### **DATA PENDIDIKAN**

SD	: SD Swasta Eria Medan	TAMAT : 2004
SMP	: SMP Harapan Mandiri Medan	TAMAT : 2007
SMA	: SMA Negeri 2 Medan	TAMAT : 2010
D3	: Teknik Informatika USU	TAMAT : 2013
S1	: Ilmu Komputer USU	TAMAT : 2015
S2	: Teknik Informatika USU	TAMAT : 2018

## **UCAPAN TERIMA KASIH**

Alhamdulillah segala puji dan syukur atas nikmat yang luas kepada Allah SWT sehingga penulis dapat menyelesaikan penyusunan tesis ini, sebagai syarat untuk memperoleh gelar Magister Komputer pada Program Magister (S-2) Ilmu Komputer Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.

Ucapan terima kasih penulis sampaikan kepada semua pihak yang telah membantu penulis dalam menyelesaikan tesis ini baik secara langsung maupun tidak langsung, teristimewa untuk kedua orangtua penulis yang sangat mengasihi dan menyayangi penulis dan memberi dukungan tiada henti. Dalam kesempatan ini, penulis ingin mengucapkan terima kasih kepada :

1. Bapak Prof. Dr. Runtung Sitepu, S.H., M.Hum. selaku Rektor Universitas Sumatera Utara.
2. Bapak Prof. Dr. Opim Salim Sitompul selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.
3. Bapak Prof. Dr. Muhammad Zarlis selaku ketua Program Studi Magister Teknik Informatika Universitas Sumatera Utara dan selaku Dosen Pembanding I yang telah memberikan arahan dan masukan yang sangat berharga kepada penulis.
4. Bapak Dr. Syahril Efendi, S.Si., M.IT selaku Sekretaris Program Studi Magister Teknik Informatika Universitas Sumatera Utara dan selaku Dosen Pembimbing I yang telah memberikan kritik dan saran serta motivasi dalam penyelesaian tesis ini.
5. Bapak Dr. Pahala Sirait, ST, M.Kom selaku Dosen Pembimbing II yang telah memberikan kritik dan saran serta motivasi dalam penyelesaian tesis ini.
6. Ibu Dr. Maya Silvi Lydia selaku Dosen Pembanding II yang telah memberikan arahan dan masukan yang sangat berharga kepada penulis.
7. Ayahanda (Alm) H. Damir Lubis, SH dan Ibunda Hj. Tri Susi Kurniarsih yang telah banyak memberikan kasih sayang, semangat, serta doa dan dukungan kepada penulis.

8. Seluruh tenaga pengajar dan pegawai di Program Studi Magister (S-2) Teknik Informatika Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.
9. Sahabat-sahabat terdekat penulis Suci Sylvana Harahap dan Adli Abdillah Nababan yang telah memberikan nasehat, bantuan, semangat dan dukungan selama ini kepada penulis.
10. Seluruh rekan-rekan seperjuangan mahasiswa Magister Teknik Informatika Kom B 2016, terkhusus untuk Annisa Fadillah Siregar, Ivana Lisa Sitepu, Farid Akbar, Sharfina Faza dan Khairul Umam Syaliman.
11. Seluruh sahabat-sahabat penulis yang tidak dapat disebutkan satu persatu yang telah memberikan semangat dan dukungan selama ini kepada penulis.
12. Semua pihak yang terlibat langsung ataupun tidak langsung yang tidak dapat penulisucapkan satu persatu yang telah membantu penyelesaian tesis ini.

Semoga Allah SWT memberikan rahmat, kasih sayang dan balasan kepada semua pihak yang telah memberikan bantuan, masukan dan semangat kepada penulis untuk menyelesaikan tesis ini. Penulis berharap tesis ini dapat bermanfaat kepada penulis dan pembaca.

Medan, 23 Juli 2018

(Ade Rizka)

## **ABSTRAK**

*Simple Additive Weighting* (SAW) merupakan salah satu metode *Multi Attribute Decision Making* (MADM) yang dikenal sebagai kombinasi linier tertimbang yang sederhana dan paling sering digunakan. Namun, berdasarkan dari beberapa penelitian, menghasilkan nilai akurasi lebih rendah dari pada metode MADM lainnya. Karena tidak ada validasi dalam sistem pembobotan untuk setiap atribut sehingga mempengaruhi proses pengambilan keputusan dan untuk beberapa atribut baru atau sub atribut yang kurang sesuai menyebabkan kesalahan dalam pengambilan keputusan dan menentukan alternatif terbaik. Pada penelitian ini, peneliti menggunakan *Gain Ratio* sebagai dasar pembobotan atribut pada *Simple Additive Weighting* (SAW). Data set yang digunakan dari *UCI Machine Learning Repository*, seperti *Cryotherapy*, *Immunotherapy*, *Indian Liver Patient Dataset* (ILPD) dan *User Knowledge Modelling*. Hasil akurasi dari penelitian ini akan dibandingkan dengan hasil nilai akurasi metode *Simple Additive Weighting* (SAW) berdasarkan bobot dari data set menggunakan Relatif Standar Deviasi. Rata-rata nilai akurasi yang diperoleh pembobotan atribut berdasarkan bobot data set sebesar 28.1825% dan bobot *Gain Ratio* sebesar 31.6975%. Maka dapat dilihat pada pembobotan atribut berdasarkan *Gain Ratio* memiliki akurasi yang lebih meningkat. Namun, pada data set *Cryotherapy* nilai akurasi berdasarkan bobot *Gain Ratio* lebih rendah 0.5% dibandingkan pembobotan atribut berdasarkan bobot dari data set dikarenakan nilai pada dataset tersebut.

Kata kunci : *Simple Additive Weighting*, *Multi Attribute Decision Making*, *Gain Ratio*

## **WEIGHTING ATTRIBUTES ON SIMPLE ADDITIVE WEIGHTING (SAW) METHOD USING GAIN RATIO IN DECISION SUPPORT SYSTEM**

### **ABSTRACT**

Simple Additive Weighting (SAW) is one of Multi Attribute Decision Making (MADM) method known as simple weighted linear combination and most used. However, based on some studies, it produces lower accuracy values than other MADM methods. Because there is no validation in the weighting system for each attribute so that it affects the decision-making process and for some new attributes or sub-attributes that are less appropriate cause errors in decision making and determine the best alternative. In this study, researchers used Gain Ratio as the basic weighting attribute on Simple Additive Weighting (SAW). Data sets used from UCI Machine Learning Repository, such as Cryotherapy, Immunotherapy, Indian Liver Patient Dataset (ILPD) and User Knowledge Modelling. The accuracy result of this research will be compared with the result of accuracy value of Simple Additive Weighting (SAW) method based on the weight of the data set using Relative Standard Deviation. The average value of accuracy obtained by attribute weighting based on the weight of data set of 28.1825% and the weight of Gain Ratio of 31.6975%. Then it can be seen on attribute weighting based on Gain Ratio has an increased accuracy. However, in the Cryotherapy data set the accuracy value based on the weight of the Gain Ratio is 0.5% lower than the weighting attribute based on the weight of the data set because the value in the dataset is spread.

**Keyword :** *Simple Additive Weighting, Multi Attribute Decision Making, Gain Ratio*

## **DAFTAR ISI**

	Hal.
Halaman Judul	i
Persetujuan	ii
Pernyataan Orisinalitas	iii
Persetujuan Publikasi	iv
Panitia Penguji	v
Riwayat Hidup	vi
Ucapan Terima Kasih	vii
Abstrak	ix
<i>Abstract</i>	x
Daftar Isi	xi
Daftar Tabel	xiii
Daftar Gambar	xv

### **BAB 1. PENDAHULUAN**

1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Tujuan Penelitian	4
1.4. Ruang Lingkup Penelitian	4
1.5. Manfaat Penelitian	4

### **BAB 2. TINJAUAN PUSTAKA**

2.1. Sistem Pendukung Keputusan	5
2.2. <i>Multi Attribute Decision Making</i> (MADM)	7
2.3. <i>Simple Additive Weighting</i> (SAW)	8
2.4. <i>Decision Tree</i>	11

2.5. <i>Gain Ratio</i>	12
2.6. <i>Relative Standart Deviation (RSD)</i>	14
2.7. Penelitian Sebelumnya	15

### **BAB 3. METODOLOGI PENELITIAN**

3.1 Rancangan Penelitian	16
3.2. Arsitektur Umum	17
3.2.1. Pembobotan atribut berdasarkan <i>Gain Ratio</i>	18
3.2.2. Klasifikasi dengan metode <i>Simple Additive Weighting (SAW)</i>	19
3.2.3. Arsitektur Simple Additive Weighting (SAW)	20
3.3 Data yang Digunakan	21
3.4. Proses Penyelesaian	22

### **BAB 4. HASIL DAN PEMBAHASAN**

4.1. Data Penelitian	34
4.2. Pembobotan Atribut	42
4.2.1. Pembobotan Data Set <i>Cryotherapy</i>	42
4.2.2. Pembobotan Data Set <i>Immunotherapy</i>	44
4.2.3. Pembobotan Data Set <i>Indian Liver Patient Dataset (ILPD)</i>	46
4.2.4. Pembobotan Data Set <i>User Knowledge Modelling</i>	49
4.3. Pengujian Data	51
4.3.1. Pengujian Data Set <i>Cryotherapy</i>	51
4.3.2. Pengujian Data Set <i>Immunotherapy</i>	54
4.3.3. Pengujian Data Set <i>Indian Liver Patient Dataset (ILPD)</i>	57
4.3.4. Pengujian Data Set <i>User Knowledge Modelling</i>	60
4.4. Analisis Hasil Pengujian	63
4.5. Pembahasan	66

### **BAB 5. KESIMPULAN DAN SARAN**

5.1. Kesimpulan	68
-----------------	----

**DAFTAR PUSTAKA**

## DAFTAR TABEL

	Hal.	
TABEL 3.1	Rincian Data <i>User Knowledge Modelling</i>	21
TABEL 3.2	Pembobotan Berdasarkan Bobot dari Data Set <i>Sample</i>	22
TABEL 3.3	Alternatif Terbaik Berdasarkan Bobot dari Data Set <i>Sample</i>	25
TABEL 3.4	Hasil Perhitungan Bobot <i>Gain Ratio</i> Setiap Atribut	28
TABEL 3.5	Alternatif Terbaik Berdasarkan Bobot <i>Gain Ratio</i>	31
TABEL 3.6	Hasil Proses Penyelesaian Data Set <i>Sample</i>	32
TABEL 4.1	Informasi Data Set <i>Cryotherapy</i>	35
TABEL 4.2	Informasi Atribut Data Set <i>Cryotherapy</i>	36
TABEL 4.3	Informasi Data Set <i>Immunotherapy</i>	37
TABEL 4.4	Informasi Atribut Data Set <i>Immunotherapy</i>	38
TABEL 4.5	Informasi Data Set ILPD	39
TABEL 4.6	Informasi Atribut Data Set ILPD	40
TABEL 4.7	Informasi Data Set <i>User Knowledge Modelling</i>	41
TABEL 4.8	Informasi Atribut Data Set <i>User Knowledge Modelling</i>	42
TABEL 4.9	Pembobotan Atribut Berdasarkan dari Data Set <i>Cryotherapy</i>	43
TABEL 4.10	Pembobotan Atribut Data <i>Cryotherapy</i> Berdasarkan <i>Gain Ratio</i>	44
TABEL 4.11	Pembobotan Atribut Berdasarkan dari Data Set <i>Immunotherapy</i>	45
TABEL 4.12	Pembobotan Atribut Data <i>Immunotherapy</i> Berdasarkan <i>Gain Ratio</i>	46
TABEL 4.13	Pembobotan Atribut Berdasarkan dari Data Set ILPD	47
TABEL 4.14	Pembobotan Atribut Data ILPD Berdasarkan <i>Gain Ratio</i>	48
TABEL 4.15	Pembobotan Atribut Berdasarkan dari Data Set <i>User Knowledge Modelling</i>	49
TABEL 4.16	Pembobotan Atribut Data <i>User Knowledge Modelling</i> Berdasarkan <i>Gain Ratio</i>	50

TABEL 4.17	Alternatif Terbaik Berdasarkan Bobot dari Data Set <i>Cryotherapy</i>	52
TABEL 4.18	Alternatif Terbaik Data Set <i>Cryotherapy</i> Berdasarkan Bobot <i>Gain Ratio</i>	53
TABEL 4.19	Alternatif Terbaik Berdasarkan Bobot dari Data Set <i>Immunotherapy</i>	55
TABEL 4.20	Alternatif Terbaik Data Set <i>Immunotherapy</i> Berdasarkan Bobot <i>Gain Ratio</i>	56
TABEL 4.21	Alternatif Terbaik Berdasarkan Bobot dari Data Set ILPD	58
TABEL 4.22	Alternatif Terbaik Data Set ILPD Berdasarkan Bobot <i>Gain Ratio</i>	59
TABEL 4.23	Alternatif Terbaik Berdasarkan Bobot dari Data Set <i>User Knowledge Modelling</i>	61
TABEL 4.24	Alternatif Terbaik Data Set <i>User Knowledge Modelling</i> Berdasarkan Bobot <i>Gain Ratio</i>	62
TABEL 4.25	Hasil Pengujian	64

## **DAFTAR GAMBAR**

	Hal.
GAMBAR 3.1 Metode <i>Simple Additive Weighting</i> (SAW) Berdasarkan Pembobotan Atribut	17
GAMBAR 3.2 Arsitektur Umum	18
GAMBAR 3.3 Tahap Pembobotan <i>Gain Ratio</i>	19
GAMBAR 3.4 Tahap metode <i>Simple Additive Weighting</i> (SAW)	19
GAMBAR 3.5 Arsitektur metode <i>Simple Additive Weighting</i> (SAW)	21
GAMBAR 4.1 Grafik Hasil Pengujian	64

# BAB 1

## PENDAHULUAN

### 1.1. Latar Belakang Masalah

*Simple Additive Weighting* (SAW) dikembangkan oleh MacCrimon pada tahun 1968, dikenal sebagai kombinasi linier tertimbang, metode penilaian, atau jumlah tertimbang (Stanujkic, 2012). *Simple Additive Weighting* (SAW) menggunakan prinsip rata-rata tertimbang. Metode ini sangat sederhana dimana nilai skala diberikan untuk setiap alternatif dengan atribut. Nilai skala kemudian dikalikan dengan bobot masing-masing yang ditetapkan oleh pengambil keputusan. Metode *Simple Additive Weighting* (SAW) disebut juga metode jumlah tertimbang dan merupakan metode yang paling sederhana dan terluas yang digunakan (Rao & Venkata, 2007).

Namun berdasarkan beberapa penelitian metode *Simple Additive Weighting* (SAW) tidak memiliki validasi yang jelas dalam sistem pembobotannya sehingga menghasilkan tingkat akurasi yang rendah. Penelitian Savitha & Chandrasekar (2011) dalam membandingkan metode *Simple Additive Weighting* (SAW) dan *Weighted Product Model* (WPM) untuk memilih jaringan terbaik dari jaringan pengunjung. Hasil penelitian dianalisis menggunakan *Relative Standard Deviation* (RSD) dari nilai peringkat, hasilnya untuk *Simple Additive Weighting* (SAW) mencapai 12,64% sedangkan WPM mencapai 35,75%.

Pada Penelitian Thor *et al.* (2013) yaitu mengkaji dan membandingkan penerapan empat teknik *Multi-Criteria Decision Making* (MCDM) dalam pengambilan keputusan pemeliharaan. Perbandingannya didasarkan pada aspek konsistensi, struktur masalah, konsep, proses inti dan keakuratan hasil akhir. Hasil dari penelitian, *Simple Additive Weighting* (SAW) tidak dapat memberikan konsistensi yang terkontrol karena tidak memiliki indeks komparatif sebagai indikator.

Penelitian yang dilakukan Velasquez & Hester (2013) menganalisis beberapa metode pengambilan keputusan *Multi-Criteria Decision Making* (MCDM) dan menentukan penerapannya dalam situasi tertentu dengan mengevaluasi keuntungan dan

kerugian relatif pada setiap metode. Hasil dari penelitian, kerugian metode *Simple Additive Weighting* (SAW) pada perkiraan yang dihasilkan tidak selalu mencerminkan situasi sebenarnya, maka hasil yang didapat mungkin tidak logis dengan nilai satu atribut tertentu sangat berbeda dari yang lain.

Pada penelitian lainnya dilakukan Kittur (2015), membahas perbedaan metode seperti *Simple Additive Weighting* (SAW), metode *Weighted Product* (WP) dan *Preference Ranking Organization Method for Enrichment Evaluation* (PROMETHEE) dalam mengevaluasi generasi optimal pembangkit listrik pada hari tertentu. Dari hasil penelitian, metode *Simple Additive Weighting* (SAW) dan metode *Weighted Product* (WP) sangat sederhana dan tidak ada validasi bobot yang dipilih, oleh karena itu hasil yang diperoleh metode *Simple Additive Weighting* (SAW) tidak begitu akurat.

Penelitian yang dilakukan Dogan *et al.* (2015) yaitu menggabungkan metode *Simple Additive Weighting* (SAW) dan pendekatan *Mixture Design* untuk menentukan kombinasi kakao optimal yang akan digunakan dalam formula minuman coklat panas. Hasil penelitian bahwa kombinasi antara *Mixture Design* dan *Simple Additive Weighting* (SAW) dapat dilakukan di industri makanan untuk tujuan pengoptimalan khususnya bidang penelitian dan pengembangan. Maka dari penelitian didapat kesimpulan bahwa dengan melakukan kombinasi metode akan didapat hasil yang lebih optimal dan akurat.

Annette *et al.* (2016) dalam penelitiannya membandingkan dan menganalisis peringkat dari *Cloud Renderfarm Services* dengan menggunakan dua metode *Multi-Criteria Decision Making* (MCDM) yaitu metode *Analytical Hierarchical Processing* (AHP) dan *Simple Additive Weighting* (SAW). Hasil penelitian metode *Simple Additive Weighting* (SAW) merupakan alternatif yang baik untuk *Analytical Hierarchical Processing* (AHP) dan lebih diutamakan bila tidak ada hierarki atribut, namun jika ada banyak tingkat hierarki dengan sub atribut maka *Simple Additive Weighting* (SAW) tidak memenuhi syarat dalam mencari nilai peringkat agregat.

Penelitian yang dilakukan Korsemov & Borrisova (2018) memodifikasi *Simple Additive Weighting* (SAW) dan *Weighted Product* (WP) yang dapat diterapkan untuk pengambilan keputusan kelompok sambil mempertimbangkan perbedaan pengetahuan

dan pengalaman para ahli. Hasil penelitian, setelah dimodifikasi kedua metode dapat digunakan untuk pemilihan lebih dari satu alternatif yang lebih baik dan memungkinkan formulasi dan solusi dari tugas optimasi kombinatorial mendapatkan alternatif terbaik. Pengujian numerik menunjukkan penerapan praktis dari kedua modifikasi yang diajukan dari model untuk pengambilan keputusan kelompok.

Berdasarkan dari beberapa penelitian, pada metode *Simple Additive Weighting* (SAW) pembobotan langsung dimasukan berdasarkan analisis kebijakan, sehingga lebih mudah dan tidak membutuhkan waktu komputasi yang lebih banyak dibandingkan metode multiatribut lainnya. Hanya saja, sebagaimana dijelaskan oleh Kittur (2015) dalam penelitiannya, *Simple Additive Weighting* (SAW) merupakan metode yang tidak memiliki validasi yang jelas dalam sistem pembobotannya, bahkan dapat menghasilkan yang tidak begitu akurat.

Metode *Simple Additive Weighting* (SAW) yang telah dikombinasikan pada penelitian Dogan *et al.* (2015) menghasilkan akurasi yang lebih optimal dan pada penelitian Korsemov & Borrisova (2018) memodifikasi *Simple Additive Weighting* (SAW) mendapatkan alternatif yang lebih baik, sehingga metode *Simple Additive Weighting* (SAW) dapat bekerja lebih optimal dengan bantuan metode lain.

Pada penelitian Priyadarsini *et al.* (2011) *Gain Ratio* merupakan modifikasi dari *Information Gain* yang mengurangi biasnya. *Gain Ratio* dapat memperbaiki *Information Gain* dengan mengambil informasi intrinsik dari setiap atribut. Oleh karena itu, pada penelitian ini akan memanfaatkan *Gain Ratio* dalam pemberian bobot terhadap atribut sebelum dilakukannya proses pengambilan keputusan. Diharapkan hal ini dapat meningkatkan akurasi metode *Simple Additive Weighting* (SAW).

## 1.2. Rumusan Masalah

Tingkat akurasi yang dihasilkan metode *Simple Additive Weighting* (SAW) rendah dikarenakan tidak ada validasi dalam sistem pembobotan untuk setiap atribut sehingga mempengaruhi proses pengambilan keputusan untuk beberapa atribut baru atau sub atribut yang kurang sesuai yang menyebabkan kesalahan dalam pengambilan keputusan dan menentukan alternatif terbaik.

### **1.3. Tujuan Penelitian**

Adapun tujuan penelitian ini adalah untuk meningkatkan nilai akurasi pada metode *Simple Additive Weighting* (SAW) dengan cara memberikan pembobotan pada setiap atribut menggunakan *gain ratio*.

### **1.4. Ruang Lingkup Penelitian**

Ruang lingkup dalam penelitian ini adalah sebagai berikut :

1. Penelitian ini hanya mengukur kinerja metode *Simple Additive Weighting* (SAW) berdasarkan tingkat akurasi yang dihasilkan.
2. Dalam pembobotan setiap atribut menggunakan pembobotan berdasarkan bobot dari data set dan bobot *gain ratio*.
3. Data yang digunakan pada penelitian ini adalah data set yang diperoleh dari *UCI Machine Learning Repository* yaitu:
  - a. Data set *Cryotherapy* merupakan data set yang berisi informasi tentang hasil pengobatan kutil yang menggunakan metode pengobatan *Cryotherapy*.
  - b. Data set *Immunotherapy* merupakan data set yang berisi informasi tentang hasil pengobatan kutil yang menggunakan metode pengobatan *Immunotherapy*.
  - c. Data set *Indian Liver Patient Dataset* (ILPD) merupakan data set yang berisi 10 variabel yaitu usia, jenis kelamin, total Bilirubin, Bilirubin langsung, protein total, albumin, rasio A / G, SGPT, SGOT dan Alkphos.
  - d. Data set *User Knowledge Modelling* merupakan data set nyata mengenai status pengetahuan siswa tentang subjek Mesin DC Listrik.

### **1.5. Manfaat Penelitian**

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut :

1. Dapat menjadi referensi dalam pembobotan atribut pada metode *Simple Additive Weighting* (SAW) dengan menggunakan *gain ratio* sebagai dasar pembobotan.
2. Memberi kontribusi kepada ilmu pengetahuan dalam bidang pengambilan keputusan dengan menggunakan metode *Simple Additive Weighting* (SAW).

## **BAB 2**

### **TINJAUAN PUSTAKA**

#### **2.1. Sistem Pendukung Keputusan**

Van Schalk (1998) mengacu pada awal 1970-an sebagai era konsep sistem pendukung keputusan diperkenalkan. Sistem pendukung keputusan adalah filosofi baru tentang bagaimana komputer dapat digunakan untuk mendukung pengambilan keputusan manajerial. Filosofi ini mewujudkan ide-ide unik dan menarik untuk desain dan implementasi sistem tersebut. Ada kontroversi sehubungan dengan interpretasi dari konsep sistem pendukung keputusan dan asal gagasan ini berasal dari istilah berikut (Franz Averweg, 2012) :

- a. Sistem: menyoroti sifat terpadu dari keseluruhan pendekatan, menyarankan konteks yang lebih luas dari mesin, pengguna, dan lingkungan keputusan.
- b. Pendukung: menjelaskan peran komputer dalam membantu bukan mengganti pembuat keputusan; dan
- c. Keputusan: menekankan fokus utama pada pengambilan keputusan dalam situasi masalah daripada kegiatan bawahan dari pencarian informasi sederhana, pemrosesan atau pelaporan.

Definisi awal dari sistem pendukung keputusan diidentifikasi sebagai sebuah sistem yang dimaksudkan untuk mendukung pengambil keputusan manajerial dalam situasi keputusan semiterstruktur. Sistem pendukung keputusan ditujukan untuk menjadi tambahan bagi para pembuat keputusan untuk memperluas kemampuannya tetapi tidak untuk menggantikan penilaianya. Pengambil keputusan pada keputusan dimana penilaian dibutuhkan atau pada keputusan yang tidak dapat sepenuhnya didukung oleh algoritma. Tidak secara khusus dinyatakan, tetapi tersirat dalam definisi awal, adalah gagasan bahwa sistem akan berbasis komputer, akan beroperasi secara interaktif online, dan lebih disukai akan memiliki kemampuan output grafis. Definisi awal terbuka untuk beberapa interpretasi. Selanjutnya beberapa definisi lain muncul yang menyebabkan

ketidaksetujuan tentang apa sebenarnya sistem pendukung keputusan (Turban *et al*, 2005).

Little (1970) mendefinisikan sistem pendukung keputusan sebagai "seperangkat prosedur berbasis model untuk memproses data dan penilaian untuk membantu seorang manajer dalam pengambilan keputusannya". Moore dan Chang (1980) berpendapat bahwa konsep terstruktur, sebagai sistem yang dapat diperluas yang mampu mendukung analisis data *ad hoc* dan pemodelan keputusan, berorientasi pada perencanaan masa depan, dan digunakan pada interval yang tidak teratur dan tidak terencana (Turban *et al*, 2005).

Bonczek *et al.* (1980) mendefinisikan sistem pendukung keputusan sebagai sistem berbasis komputer yang terdiri dari tiga komponen yang saling berinteraksi yaitu sistem bahasa, sistem pengetahuan, dan sistem pemrosesan masalah. Konsep-konsep yang disediakan oleh definisi ini penting untuk memahami hubungan antara sistem pendukung keputusan dan pengetahuan. Dan, Keen (1980) mendefinisikan sistem pendukung keputusan sebagai produk dari proses perkembangan dimana pengguna sistem pendukung keputusan, pembangun sistem pendukung keputusan, dan sistem pendukung keputusan itu sendiri saling mempengaruhi satu sama lain, menghasilkan evolusi dan pola penggunaan sistem (Turban *et al*, 2005).

Karakteristik dan kapabilitas sistem pendukung keputusan adalah sebagai berikut (Turban *et al*, 2005) :

1. Dukungan untuk pengambil keputusan, terutama dalam situasi semiterstruktur dan tidak terstruktur, dengan menyatukan penilaian manusia dan terkomputerisasi.
2. Dukungan untuk semua level manajerial, mulai dari eksekutif puncak hingga manajer lini.
3. Dukungan untuk individu maupun kelompok. Masalah yang kurang terstruktur sering membutuhkan keterlibatan individu dari berbagai departemen dan organisasi tingkat atau bahkan dari organisasi yang berbeda.
4. Dukungan untuk keputusan yang interdependen dan berurutan. Keputusan dapat dibuat satu kali, beberapa kali, atau berulang kali.

5. Dukungan dalam semua fase proses pengambilan keputusan, yaitu *intelligence*, *design*, *choice*, dan *implementation*.
6. Mendukung dalam berbagai proses dan gaya pengambilan keputusan.
7. Adaptivitas dari waktu ke waktu. Pembuat keputusan harus reaktif, mampu menghadapi kondisi yang berubah dengan cepat, dan mampu menyesuaikan sistem pendukung keputusan untuk memenuhi perubahan ini.
8. Kemudahan penggunaan interaktif.
9. Peningkatan efektivitas pengambilan keputusan (akurasi, ketepatan waktu, kualitas) daripada efisiensinya (biaya pembuatan keputusan).
10. Kontrol penuh oleh pembuat keputusan atas semua langkah dari proses pengambilan keputusan dalam memecahkan suatu masalah. sistem pendukung keputusan secara khusus bertujuan untuk mendukung dan tidak mengganti pembuat keputusan.
11. Pengguna akhir dapat mengembangkan dan memodifikasi sistem sederhana sendiri.
12. Model umumnya digunakan untuk menganalisis situasi pengambilan keputusan. Kemampuan pemodelan memungkinkan berekspeten dengan strategi yang berbeda di bawah konfigurasi yang berbeda.
13. Akses disediakan untuk berbagai sumber data, format, dan jenis, mulai dari sistem informasi geografis (GIS) hingga yang berorientasi objek.
14. Dapat digunakan sebagai *standalone* yang digunakan oleh pembuat keputusan individu di satu lokasi atau didistribusikan ke seluruh organisasi dan di beberapa organisasi di sepanjang rantai persediaan.

## 2.2. *Multi Attribute Decision Making (MADM)*

*Multi Attribute Decision Making* adalah metode yang digunakan untuk mencari alternatif yang paling optimal dari sejumlah alternatif yang ada berdasarkan kriteria atau atribut tertentu. *Multi Attribute Decision Making* menentukan nilai bobot untuk setiap atribut, selanjutnya dilakukan proses perankingan untuk menyeleksi sejumlah alternatif yang ada. Nilai suatu atribut mendeskripsikan karakteristik, kualitas, dan kinerja

alternatif. Bobot atribut berfungsi untuk mengukur nilai bobot kepentingan setiap atribut. Dalam mencari nilai bobot setiap atribut terdapat 3 kategori pendekatan yaitu, pendekatan subjektif, pendekatan objektif dan pendekatan hibrida. Pendekatan subjektif, menentukan nilai bobot berdasarkan subjektifitas dari pengambilan keputusan atau memanfaatkan preferensi pengambilan keputusan. Pada pendekatan objektif, menentukan nilai bobot berdasarkan informasi yang objektif atau nilai bobot dihitung secara matematis. Dan pada pendekatan hibrida, menentukan nilai bobot berdasarkan gabungan dari preferensi pembuat keputusan dan informasi yang objektif atau nilai bobot yang dihitung secara matematis. Beberapa metode yang dapat digunakan dalam menyelesaikan masalah *Multi Attribute Decision Making*, adalah sebagai berikut (Ding *et al.* 2016; Sembiring *et al.* 2018):

- a. *Simple Additive Weighting Method* (SAW)
- b. *Weighted Product* (WP)
- c. ELECTRE
- d. *Technique for Order Preference by Similarity to Ideal Solution* (TOPSIS).
- e. *Analytic Hierarchy Process* (AHP)

### **2.3. Simple Additive Weighting (SAW)**

*Simple Additive Weighting* (SAW) disebut juga sebagai kombinasi linier tertimbang atau metode *scoring* atau metode *weighted sum* yang sederhana dan paling sering digunakan dalam teknik keputusan multi atribut. *Simple Additive Weighting* (SAW) berdasarkan pada rata-rata tertimbang. Nilai evaluasi dihitung untuk setiap alternatif dari atribut, dengan mengalikan nilai skala yang telah diberikan kepada alternatif dari atribut dengan nilai bobot kepentingan relatif yang diberikan oleh pembuat keputusan dan menjumlahkan produk untuk seluruh kriteria (Savitha & Chandraekar, 2011). *Simple Additive Weighting* (SAW) mampu menyeimbangkan antara setiap kriteria atau atribut, bersifat intuitif dalam mengambil keputusan, dan proses perhitungan sederhana sehingga tidak perlu menggunakan program komputer yang rumit. Metode ini dapat diterapkan dalam beberapa area yaitu *water management*, bisnis, dan manajemen keuangan (Velasquez & Hester, 2013).

Penilaian yang diterapkan pada SAW membutuhkan, identifikasi tujuan dan alternatif, evaluasi alternatif, penentuan bobot sub objektif, agregasi aditif (kumpulan sejumlah nilai yang ditambahkan) dari nilai preferensi parsial tertimbang dan analisis sensitif. Hal ini menggunakan penilaian langsung pada skala standar hanya dalam atribut kualitatif murni. Untuk nilai atribut numerik dihitung dengan nilai yang telah dinormalisasi agar sesuai dengan skala standar (Savitha & Chandraekar, 2011).

Dalam Metode *Simple Additive Weighting* (SAW) terdapat dua atribut yaitu atribut keuntungan atau manfaat dan atribut biaya. Atribut keuntungan atau manfaat yaitu jika nilai atribut semakin besar maka atribut semakin baik. Dan atribut biaya yaitu, jika nilai atribut semakin kecil maka semakin baik. Kedua atribut memiliki perbedaan yang mendasar yaitu dalam pemilihan atribut ketika mengambil keputusan (Ding *et al.* 2016).

Normalisasi adalah upaya untuk menghilangkan dimensi (ukuran unit) dari setiap atribut. Normalisasi bertujuan agar dapat dilakukan pembandingan alternatif menggunakan satu atribut maupun membandingkan antar atribut. Adapun langkah-langkah dalam metode *Simple Additive Weighting* (SAW) adalah sebagai berikut (Sembiring *et al.* 2018) :

1. Membuat matriks keputusan Z berukuran  $m \times n$ , dimana  $m =$  alternatif ( $A_i$ ) yang akan dipilih dan  $n =$  kriteria atau atribut ( $C_j$ ).
2. Memberikan nilai  $x$  setiap alternatif ( $i$ ) pada setiap kriteria atau atribut ( $j$ ) yang sudah ditentukan, dimana  $i=1,2,\dots,m$  dan  $j=1,2,\dots,n$  pada matriks keputusan Z.

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1j} \\ \vdots & & & \vdots \\ x_{i1} & x_{i2} & \cdots & x_{ij} \end{bmatrix}$$

3. Memberikan nilai bobot preferensi ( $W$ ) oleh pengambil keputusan untuk masing-masing kriteria atau atribut yang sudah ditentukan.

$$W = [ W_1 \ W_2 \ W_3 \ W_4 ]$$

4. Melakukan normalisasi matriks keputusan Z berdasarkan persamaan (2.1) dan (2.2) sesuai dengan jenis kriteria atau atribut (keuntungan dan biaya) sehingga diperoleh matriks ternormalisasi ( $R$ ).

a. Jika  $j$  adalah keuntungan

$$R_{ij} = \frac{X_{ij}}{\text{Max } X_{ij}} \quad (2.1)$$

b. Jika  $j$  adalah biaya

$$R_{ij} = \frac{\text{Min } X_{ij}}{X_{ij}} \quad (2.2)$$

Keterangan :

- a. Atribut keuntungan : apabila nilai memberikan keuntungan atau manfaat bagi pengambil keputusan. Jika atribut keuntungan maka nilai ( $x_{ij}$ ) setiap kolom dibagi dengan nilai ( $\text{Max } x_{ij}$ ) maksimum dari tiap kolom.
  - b. Atribut biaya : apabila menimbulkan biaya bagi pengambil keputusan. Jika atribut biaya maka nilai ( $\text{Min } x_{ij}$ ) dari tiap kolom dibagi dengan nilai ( $x_{ij}$ ) setiap kolom.
5. Hasil dari nilai rating (yang dapat dibandingkan antar atribut) kerja ternormalisasi ( $r_{ij}$ ) membentuk matrik ternormalisasi ( $R$ )

$$R = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1j} \\ \vdots & & & \vdots \\ r_{i1} & r_{i2} & \cdots & r_{ij} \end{bmatrix}$$

6. Melakukan proses perankingan dengan cara mengalikan matriks ternormalisasi ( $R$ ) dengan nilai bobot preferensi ( $W$ ).
7. Nilai preferensi atau nilai yang diutamakan untuk setiap alternatif ( $V_i$ ) diperoleh dengan cara menjumlahkan hasil kali antara matrik ternormalisasi ( $R$ ) dengan bobot preferensi ( $W$ ).

$$V_i = \sum_{j=1}^n W_j R_{ij} \quad (2.3)$$

Dimana :

$V_i$  : nilai preferensi untuk setiap alternatif

$W_j$  : nilai bobot dari setiap atribut

$R_{ij}$  : nilai rating kerja ternormalisasi

Nilai  $V_i$  yang lebih besar mengidentifikasi bahwa alternatif  $A_i$  merupakan alternatif terbaik.

## 2.4. Decision Tree

*Decision tree* merupakan pembelajaran tentang pohon keputusan dari kelas yang diberi label *training samples*. *Decision tree* dibangun dari *node*, cabang dan daun yang menunjukkan variabel, kondisi dan hasil. *Decision tree* memiliki struktur *tree* seperti *flowchart*, dimana setiap *node* internal (*non leaf node*) menunjukkan pengujian pada atribut, masing-masing cabang mewakili hasil dari pengujian, dan setiap *node* daun (atau *node* terminal) mewakili kelas. Variabel yang paling prediktif berada pada *node* paling atas dalam sebuah *tree* yaitu *node* akar. Beberapa algoritma *decision tree* hanya menghasilkan *tree* biner (dimana masing-masing *node* internal bercabang ke dua *node* lainnya), sedangkan yang lain dapat menghasilkan pohon non-biner. Beberapa algoritma yang dapat digunakan *decision tree* yaitu, ID3, CART, dan C4.5 (Agrawal & Gupta, 2013).

C4.5 mengadopsi pendekatan *greedy* (yaitu, *non-back tracking*) dimana *decision tree* dibangun dalam pembagian rekursif dan cara menaklukkan *top-down*. Kebanyakan algoritma untuk induksi *decision tree* juga mengikuti pendekatan *top-down*, yang dimulai dengan kumpulan *training samples* dan label kelas terkait. Set *training* secara rekursif dipartisi menjadi himpunan bagian yang lebih kecil saat *tree* sedang dibangun. Ukuran dalam pemilihan atribut akan memberikan peringkat untuk setiap atribut yang menggambarkan *training samples* yang diberikan. Atribut yang memiliki nilai terbaik untuk pengukuran akan dipilih sebagai atribut pemisahan untuk *samples* yang diberikan. Adapun langkah-langkah dalam proses *decision tree* adalah sebagai berikut (Agrawal & Gupta, 2013):

1. Memilih data set sebagai input ke algoritma untuk diproses.
2. Memilih pengklasifikasi.
3. Menghitung *entropy*, *information gain*, dan *gain ratio* setiap atribut.
4. Memproses input yang diberikan data set sesuai dengan algoritma data mining C4.5 yang telah ditentukan.
5. Menurut algoritma yang ditetapkan dari data mining C4.5 yang ditingkatkan, melakukan pemrosesan input data yang diberikan.

6. Data yang harus diinput ke cara kerja pembuatan *tree* yang diberikan oleh C4.5 dan perbaikan prosesor C4.5. Generator *tree* menghasilkan *tree* untuk C4.5 dan algoritma *decision tree* C4.5 yang ditingkatkan.

## 2.5. Gain Ratio

Algoritma C4.5 adalah metode pohon keputusan dalam pemilihan atributnya berdasarkan dari *Gain ratio* yang dikembangkan oleh Ross Quinlan. *Gain ratio* merupakan modifikasi dari *Information Gain* yang mengurangi biasnya. *Gain ratio* memperbaiki *information gain* dengan mengambil informasi intrinsik dari setiap atribut. (Priyadarsini, et al. 2011). Kelebihan algoritma C4.5 adalah signifikan, sehingga dapat dipilih. Tetapi efisiensinya harus ditingkatkan untuk memenuhi peningkatan dramatis dalam permintaan untuk data dalam jumlah besar (Agrawal & Gupta, 2013). Adapun langkah-langkah dalam penentuan *Gain Ratio* adalah sebagai berikut (Dujena & Puyalnithi, 2017; Mitchell, 1997) :

- a. *Entropy* kumpulan data adalah jumlah nilai yang dibutuhkan untuk menyatakan atribut. Pengurangan yang diharapkan dalam *entropy* disebabkan oleh partisi sesuai dengan atribut. Hitung nilai *entropy* kumpulan data pada masing – masing atribut, dengan persamaan :

$$\text{Entropy}(S) = \sum_{i=1}^n -pi * \log_2 pi \quad (2.4)$$

Dimana:

$S$  : Himpunan Kasus

$n$  : Jumlah Partisi  $S$

$pi$  : Proporsi dari  $S_i$  terhadap  $S$

- b. *Information gain* adalah salah satu salah satu atribut seleksi yang digunakan untuk memilih pengujian atribut setiap *node* pada *tree*. Atribut dengan *information gain* tertinggi dipilih sebagai pengujian atribut dari suatu *node*. Hitung nilai *information gain* pada masing-masing atribut dengan persamaan :

$$\text{Information Gain}(S, A) = \text{Entropy}(S) - \sum_{i=1}^n \frac{|S_i|}{|S|} \times \text{Entropy}(S_i) \quad (2.5)$$

Dimana :

$S$  : Keseluruhan *Dataset*

$A$  : Atribut Subset

$n$  : Jumlah Partisi Atribut A

$|S_i|$  : Ukuran Subset dari Dataset yang dimiliki atribut pada A partisi ke-i

$|S|$  : Ukuran Jumlah Kasus dalam Dataset

- c. Jika nilai *Split Information* mendekati 0, rasio menjadi tidak stabil. Dimana nilai *information gain* dari pengujian yang dipilih harus besar, setidaknya sama besar dengan rata-rata *gain* dari semua pengujian yang telah diperiksa. Hitung nilai *Split Information* untuk masing-masing atribut dengan persamaan berikut :

$$SplitInfo_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2\left(\frac{|D_j|}{|D|}\right) \quad (2.6)$$

Dimana :

$D$  : Keseluruhan Dataset

$A$  : Atribut Subset

$v$  : Jumlah Partisi Atribut A

$|D_j|$  : Ukuran Subset dari Dataset yang dimiliki atribut pada A partisi ke-j

$|D|$  : Ukuran Jumlah Kasus dalam Dataset

- d. Parameter menormalisasi nilai *information gain* dan tidak membiarkan bias pada atribut tersebut. Normalisasi dilakukan dengan membagi *information gain* atribut oleh *SplitInfo*, hasil nilai tersebut dikenal sebagai *gain ratio* dari suatu atribut. Berikut perhitungan *gain ratio* dari setiap atribut dengan menggunakan persamaan (2.7) :

$$Gain Ratio (A) = \frac{Gain (A)}{SplitInfo(A)} \quad (2.7)$$

Semakin banyak *information gain* didapat, maka akan semakin kuat atributnya. Maka, partisi akan terjadi pada atribut yang memiliki perolehan informasi tertinggi. Konsep *Split Info* pada suatu atribut diperkenalkan oleh C4.5 untuk menghilangkan bias. (Dujena & Puyalnithi, 2017). *Gain ratio* ditemukan pada algoritma C4.5, dimana *gain ratio* digunakan untuk menghitung pengaruh atribut terhadap target dari suatu data

(Mitchell, 1997). *Gain Ratio* merupakan pengembangan dari *information gain*, dimana *gain ratio* menghilangkan nilai bias dari setiap atribut.

## 2.6. Relative Standard Deviation (RSD)

*Relative Standard Deviation* (RSD) digunakan untuk menentukan nilai akurasi. *Relative standard deviation* lebih mudah dalam membandingkan seberapa baik suatu nilai. *Relative standard deviation* dinyatakan dalam persen dan diperoleh dengan mengalikan standar deviasi ( $x$ ) oleh 100 dan membagi data set dengan rata-rata (Savitha & Chandraekar, 2011). Standar deviasi adalah ukuran seberapa tepat rata-rata, yaitu seberapa baik angka-angka individu sesuai satu sama lain. Standar deviasi juga merupakan indeks yang mewakili penyebaran dalam satu set nilai. Jika nilai dikelompokkan dekat di sekitar nilai rata-rata, standar deviasi akan kecil, dan jika nilai tersebar, standar deviasinya akan besar.

Adapun perhitungan standar deviasi dan *Relative Standard Deviation* (RSD) adalah sebagai berikut (Savitha & Chandraekar, 2011):

$$S = \sqrt{\frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n-1}} \quad (2.8)$$

Dimana :

$S$  : *Standard deviation*

$\sum x_i^2$  : Jumlah kuadrat pengukuran individu

$\sum x_i$  : Jumlah pengukuran individu

$n$  : Jumlah sampel data yang dianalisis

Selanjutnya perhitungan *Relative Standard Deviation* (RSD) adalah sebagai berikut :

$$RSD = \frac{S}{\bar{x}} \times 100 \quad (2.9)$$

Dimana :

RSD : *Relative Standard Deviation*

$S$  : *Standard deviation*

$\bar{x}$  : *Mean* dari data

## **2.7. Penelitian Sebelumnya**

Penelitian ini dilakukan berdasarkan beberapa penelitian sebelumnya yang berkaitan, maka dibawah ini akan dipaparkan beberapa penelitian sebelumnya.

Penelitian yang dilakukan R. Chou (2013) menyajikan metode *Weighted Linear Combination Ranking Technique* (WLCRT) yang diterapkan ke MCDA sebagai metode pembobotan yang valid yang terkait dengan operasi agregasi yang efektif. Hasil penelitian menunjukkan hasil analisis sensitifitas metode WLCRT lebih stabil dan kredibel dalam alternatif peringkat dibandingkan dengan metode *Simple Additive Weighting* (SAW).

Penelitian yang dilakukan Dashore *et al.* (2013) mengevaluasi produk laptop dengan menggunakan metode *Entropy* untuk mengevaluasi bobot masing-masing atribut dan metode *Multi-Criteria Decision Making* (MCDM) untuk memilih pilihan terbaik di antara berbagai alternatif. Hasil penelitian menunjukkan bahwa hasil evaluasi peringkat produk dari metode TOPSIS, SAW dan WPM lebih akurat karena mendukung produk alternatif yang sama karena menggunakan *entropy* untuk mengevaluasi bobot setiap atribut.

Penelitian yang dilakukan B. Leoneti (2016) mengevaluasi kecenderungan prediksi peringkat awal dari metode peringkat MCDM utama, yaitu: SAW, TOPSIS, ELECTRE III, PROMETHEE II dan TODIM dalam mengevaluasi tujuan wisata. Hasil penelitian menunjukkan tingkat akurasi TOPSIS mencapai 50% dari setidaknya tiga pertandingan dalam urutan dua puluh peserta, diikuti oleh PROMETHEE II (40%), ELECTRE II (30%), TODIM (25%) dan SAW (25%). TOPSIS memprediksi dengan benar 15 kali peringkat alternatif pertama, yang berarti 79% akurasi dan metode SAW 74%.

Penelitian yang dilakukan M. de Brito & Evers (2016) meninjau penerapan *Multi-Criteria Decision Making* (MCDM) terhadap manajemen resiko banjir. Hasil penelitian menunjukkan bahwa metode AHP (42.42%) paling banyak digunakan karena strukturnya sangat mudah, fleksibel, dan mudah dimengerti, metode kedua TOPSIS (13.33%) dan metode selanjutnya *Simple Additive Weighting* (SAW) (12.73%). Namun, analisis ketidakpastian tetap menjadi masalah, terutama mengenai definisi bobot atribut.

## **BAB 3**

### **METODOLOGI PENELITIAN**

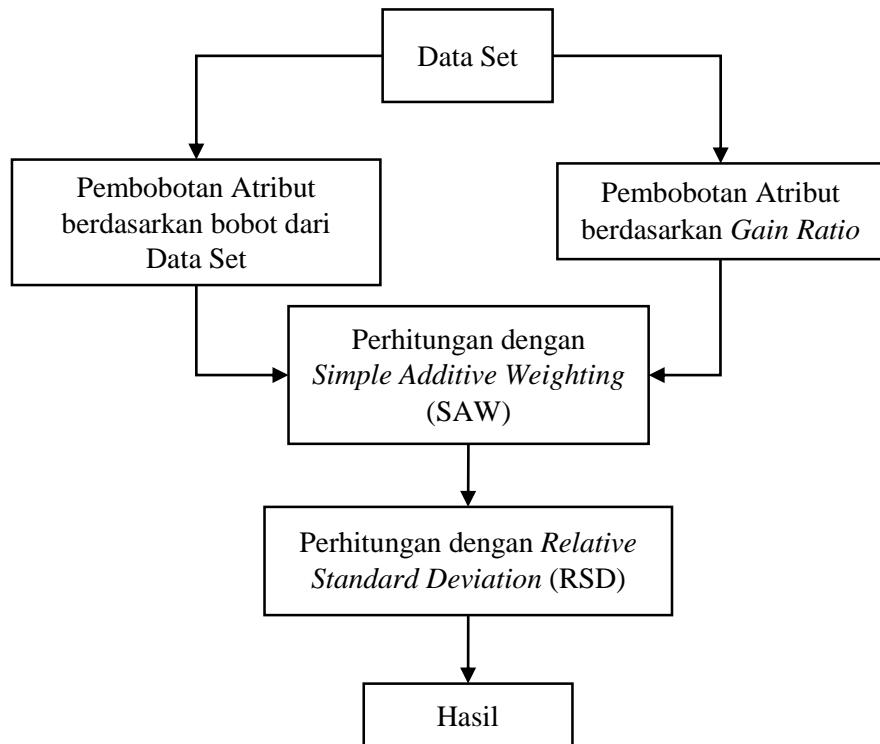
Bab ini menjelaskan tahapan yang akan dilakukan dalam penelitian yaitu rancangan yang akan dilakukan dalam penelitian, arsitektur umum yang diuraikan menjadi beberapa proses dan data yang digunakan pada proses penyelesaian sebagai dasar pembobotan atribut metode *Simple Additive Weighting* (SAW).

#### **3.1. Rancangan Penelitian**

Pada penelitian ini metode *Simple Additive Weighting* (SAW) menggunakan dua pembobotan atribut yang berbeda yaitu, pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan bobot *gain ratio*. Penelitian ini menggunakan *gain ratio* sebagai dasar pembobotan terhadap setiap atribut yang menjadi alat ukur dalam relasi antara atribut pada data. Dengan memberikan bobot yang sesuai pada setiap atribut maka diharapkan dapat mengurangi pengaruh dari atribut yang tidak memiliki validasi bobot yang akurat dalam hasil pengambilan keputusan menggunakan metode *Simple Additive Weighting* (SAW), sehingga mampu meningkatkan akurasi dari proses pengambilan keputusan tersebut dan dapat menentukan alternatif terbaik.

Dalam pembobotan atribut data set dengan menggunakan pembobotan berdasarkan bobot dari data set dan menggunakan pembobotan berdasarkan *gain ratio*, maka bobot preferensi atribut yang telah ditentukan dan akan digunakan untuk perhitungan nilai preferensi setiap alternatif data set dengan cara menjumlahkan hasil kali antara matriks yang sudah ternormalisasi dengan pembobotan berdasarkan bobot dari data set maupun pembobotan berdasarkan *gain ratio*. Hasil preferensi setiap alternatif yang diperoleh dari metode *Simple Additive Weighting* (SAW) berupa nilai yang akan menentukan akurasi. Dalam menentukan akurasi, nilai preferensi setiap atribut akan dihitung dengan menggunakan *Relative Standard Deviation* (RSD). Hasil dari perhitungan akan menentukan tingkat akurasi metode *Simple Additive Weighting* (SAW) dengan menggunakan dua pembobotan atribut yang berbeda. Secara umum tahapan dari metode

*Simple Additive Weighting* (SAW) dengan menggunakan dua pembobotan atribut yang berbeda dalam penelitian ini ditunjukan pada gambar 3.1.



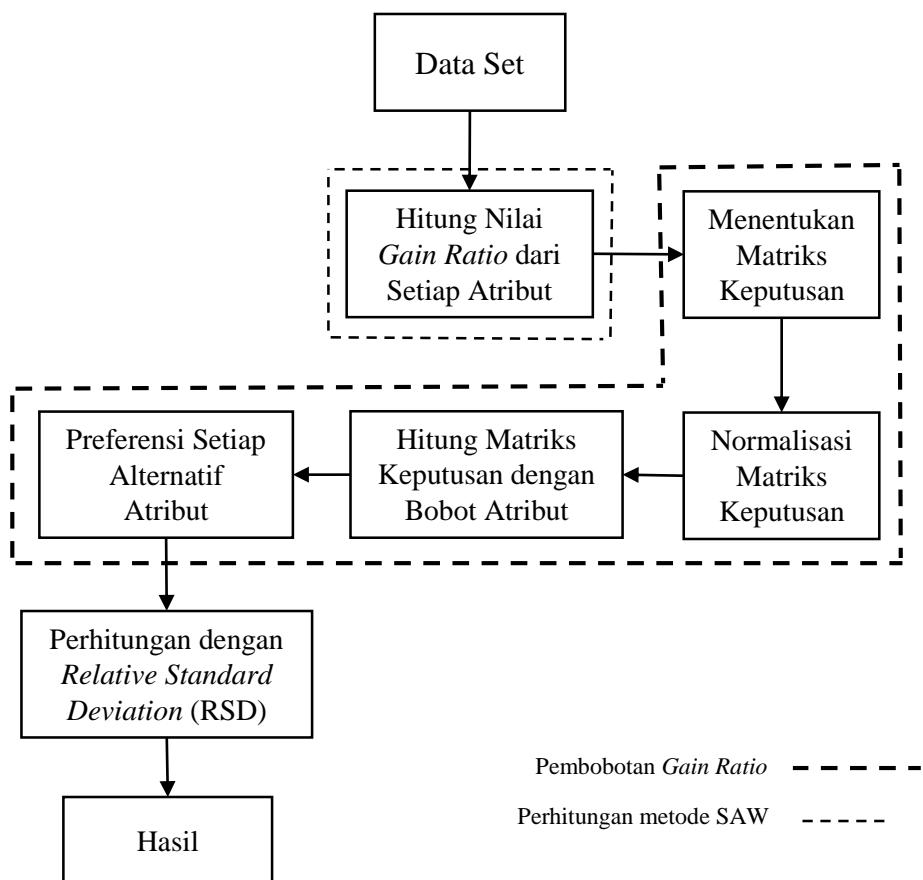
**Gambar 3.1** Metode *Simple Additive Weighting* (SAW) Berdasarkan Pembobotan Atribut

### 3.2. Arsitektur Umum

Arsitektur penelitian secara umum dapat dibagi menjadi beberapa tahap yaitu, tahap pembobotan atribut berdasarkan *gain ratio*, tahap perhitungan metode *Simple Additive Weighting* (SAW) dan arsitektur metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan bobot dari data set. Pada pembobotan atribut berdasarkan *gain ratio* yang menjadi dasar pemberian bobot terhadap setiap atribut dari data set diharapkan jika semakin tinggi *gain ratio* dari suatu atribut maka semakin besar akurasi terhadap data, sehingga bobot dari setiap atribut juga semakin tinggi.

Data set dengan beberapa atribut yang telah ditentukan akan dilakukan proses penentuan bobot berdasarkan *gain ratio* dengan beberapa tahap yang akan dijelaskan pada *sub bab level 1* selanjutnya dilakukan proses perhitungan dengan menggunakan

metode *Simple Additive Weighting* (SAW) yaitu, menentukan matriks keputusan dari data set, menormalisasikan matriks keputusan yang selanjutnya dihitung dengan bobot preferensi atribut berdasarkan bobot *gain ratio* dan menghasilkan nilai preferensi setiap atribut. Dalam menentukan akurasi, nilai preferensi setiap atribut dihitung dengan menggunakan *Relative Standard Deviation* (RSD) dan menghasilkan hasil akurasi dari metode *Simple Additive Weighting* (SAW). Adapun arsitektur umum dalam penelitian ini dapat dilihat pada gambar 3.2.

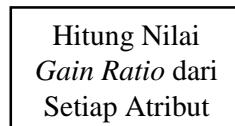


**Gambar 3.2** Arsitektur Umum

### 3.2.1. Pembobotan atribut berdasarkan *Gain Ratio*

Pada penelitian ini *gain ratio* digunakan sebagai alat ukur untuk melihat relasi antara setiap atribut data. *Gain ratio* juga akan digunakan sebagai dasar pembobotan terhadap setiap atribut dari data set. Hasil pembobotan setiap atribut mempengaruhi nilai preferensi setiap alternatif dan menentukan akurasi metode *Simple Additive Weighting*

(SAW). Adapun tahap pembobotan berdasarkan *gain ratio* dapat dilihat pada gambar 3.3.



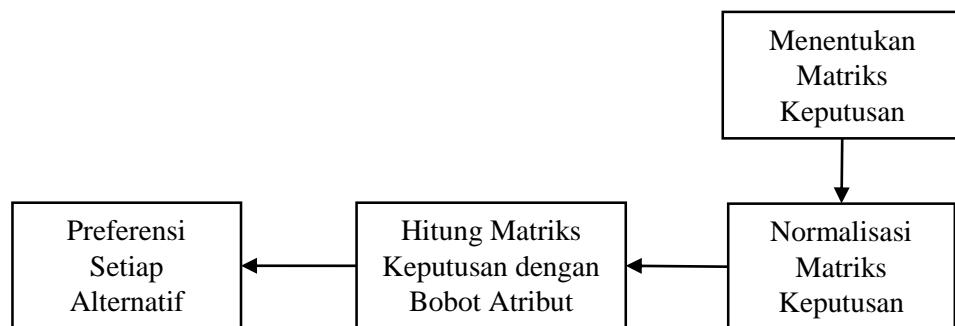
**Gambar 3.3** Tahap Pembobotan *Gain Ratio*

Berdasarkan gambar 3.3, tahap pembobotan atribut berdasarkan bobot *gain ratio* dapat dijelaskan sebagai berikut :

- i. Hitung *entropy* seluruh data menggunakan persamaan (2.4)
- ii. Hitung *gain* atau *Information Gain* sebagai salah satu atribut seleksi yang digunakan untuk memilih atribut setiap alternatif pada data menggunakan persamaan (2.5)
- iii. Hitung *Split Information* untuk setiap atribut menggunakan persamaan (2.6)
- iv. Hitung nilai *Gain Ratio* dari setiap atribut dengan membagi nilai *information gain* dengan *split info* menggunakan persamaan (2.7)

### 3.2.2. Perhitungan dengan metode Simple Additive Weighting (SAW)

Tahap selanjutnya setelah bobot setiap atribut diperoleh dari tahap pembobotan *gain ratio* yaitu melakukan perhitungan dengan menggunakan metode *Simple Additive Weighting* (SAW). Adapun tahap metode *Simple Additive Weighting* (SAW) dapat dilihat pada gambar 3.4.



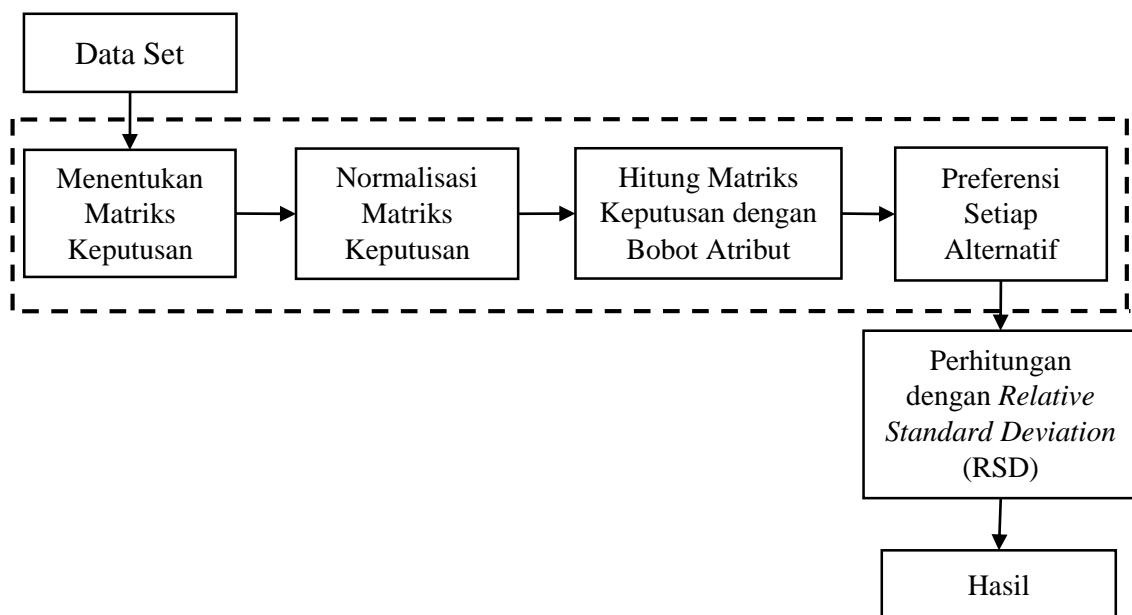
**Gambar 3.4** Tahap metode *Simple Additive Weighting* (SAW)

Berdasarkan gambar 3.4, tahap perhitungan menggunakan metode *Simple Additive Weighting* (SAW) dapat dijelaskan sebagai berikut :

8. Menentukan matriks keputusan Z berukuran  $m \times n$ , dimana  $m =$  alternatif ( $A_i$ ) yang akan dipilih dan  $n =$  kriteria atau atribut ( $C_j$ ) **berdasarkan data set.**
9. Memberikan nilai  $x$  setiap alternatif ( $i$ ) pada setiap kriteria atau atribut ( $j$ ) yang sudah ditentukan data set.
10. Memberikan nilai bobot preferensi ( $W$ ) berdasarkan bobot *gain ratio* oleh pengambil keputusan untuk masing-masing kriteria atau atribut yang sudah ditentukan.
11. Melakukan normalisasi matriks keputusan Z dengan menggunakan persamaan (2.1) dan (2.2).
12. Hasil dari nilai rating kerja ternormalisasi ( $r_{ij}$ ) membentuk matriks ternormalisasi ( $R$ ).
13. Nilai preferensi untuk setiap alternatif ( $V_i$ ) diperoleh dengan cara menjumlahkan hasil kali antara matriks ternormalisasi ( $R$ ) dengan bobot preferensi ( $W$ ) **dengan menggunakan persamaan (2.3).**

### 3.2.3. Arsitektur Simple Additive Weighting (SAW)

Pada proses metode Simple Additive Weighting (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set, sistem pembobotan ditentukan berdasarkan beberapa pendekatan yaitu, pendekatan subjektif, pendekatan objektif dan pendekatan hibrida. Sehingga bobot sudah ditentukan terlebih dahulu oleh pengambil keputusan atau pakar dari sumber data. Berdasarkan data set ditentukan matriks keputusan, yang akan dinormalisasi untuk selanjutnya dilakukan proses perhitungan matriks keputusan dengan pembobotan atribut berdasarkan bobot dari data set, dan akan dihitung nilai preferensi dari setiap alternatif. Hasil dari nilai preferensi setiap alternatif akan dihitung dengan menggunakan *Relative Standard Deviation* (RSD) dan menghasilkan hasil akurasi dari metode *Simple Additive Weighting* (SAW). Adapun arsitektur metode *Simple Additive Weighting* (SAW) dengan pembobotan atribut berdasarkan bobot dari data set dapat dilihat pada gambar 3.5.



**Gambar 3.5** Arsitektur metode *Simple Additive Weighting* (SAW)

### 3.3. Data yang Digunakan

Pada *sample* proses penyelesaian menggunakan data set *User Knowledge Modelling* yang berasal dari *UCI Machine Learning Repository*. Data set *User Knowledge Modelling* yang digunakan pada *sample* proses penyelesaian diambil sebanyak 10 *record* data yang memiliki 5 atribut yaitu, *STG* (C1), *SCG* (C2), *STR* (C3), *LPR* (C4) dan *PEG* (C5) dengan *result* UNS (very low, low, middle, high). Adapun rincian 10 *record* data dari data set *User Knowledge Modelling* dapat dilihat pada table 3.1.

**Tabel 3.1** Rincian Data *User Knowledge Modelling*

No.	Alternatif	STG(C1)	SCG(C2)	STR(C3)	LPR(C4)	PEG(C5)	UNS
1.	1	0	0	0	0	0	very_low
2.	2	0.08	0.08	0.1	0.24	0.9	High
3.	3	0.06	0.06	0.05	0.25	0.33	Low
4.	4	0.1	0.1	0.15	0.65	0.3	Middle
5.	5	0.08	0.08	0.08	0.98	0.24	Low
6.	6	0.09	0.15	0.4	0.1	0.66	Middle

**Tabel 3.1** Rincian Data *User Knowledge Modelling (Lanjutan)*

7.	7	0.1	0.1	0.43	0.29	0.56	Middle
8.	8	0.15	0.02	0.34	0.4	0.01	very_low
9.	9	0.2	0.14	0.35	0.72	0.25	Low
10	10	0	0	0.5	0.2	0.85	High

Berdasarkan table 3.1 terdapat 10 data *record* yang berbeda pada data set *User Knowledge Modelling* yang digunakan pada proses penyelesaian metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan bobot *gain ratio*.

#### 3.4. Proses Penyelesaian

Pada proses penyelesaian dengan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan berdasarkan *gain ratio*. Pada metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set, pembobotan sudah ditentukan oleh data set maupun pakar, maka bobot tersebut adalah bobot asli dari data set. Pembobotan atribut berdasarkan bobot dari data set diperoleh dari jurnal “The Development of Intuitive Knowledge Classifier and The Modelling of Domain Dependent Data” (Kahraman *et al*, 2013) berdasarkan persetujuan sumber data set yaitu H. Tolga Kahraman via email ([htolgakahraman@yahoo.com](mailto:htolgakahraman@yahoo.com)). Adapun pembobotan atribut berdasarkan dari data set dapat dilihat pada tabel 3.2.

**Tabel 3.2** Pembobotan Berdasarkan Bobot dari Data Set *Sample*

No.	Atribut	Bobot dari Data Set
1.	<i>STG</i> (C1)	0.64886
2.	<i>SCG</i> (C2)	0.10922
3.	<i>STR</i> (C3)	0.98214
4.	<i>LPR</i> (C4)	0.89958
5.	<i>PEG</i> (C5)	0.98539

Pada tabel 3.2 dapat dilihat untuk pembobotan atribut berdasarkan dari data set *User Knowledge Modelling* sebanyak 10 data *record* dengan batas nilai bobot atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai atribut *STG* (C1) sebesar 0.64886, atribut *SCG* (C2) sebesar 0.10922, atribut *STR* (C3) sebesar 0.98214, atribut *LPR* (C4) sebesar 0.89958 dan atribut *PEG* (C5) sebesar 0.98539. Dari pembobotan setiap atribut yang sudah ditentukan berdasarkan bobot dari data set maka dilanjutkan dengan proses perhitungan metode *Simple Additive Weighting* (SAW). Proses penyelesaian metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan dari data set adalah sebagai berikut :

1. Membuat matriks keputusan Z berukuran  $m \times n$ , dimana  $m = \text{alternatif } (A_i)$  yang akan dipilih dan  $n = \text{kriteria atau atribut } (C_j)$

$$X = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0.08 & 0.08 & 0.1 & 0.24 & 0.9 \\ 0.06 & 0.06 & 0.05 & 0.25 & 0.33 \\ 0.1 & 0.1 & 0.15 & 0.65 & 0.3 \\ 0.08 & 0.08 & 0.08 & 0.98 & 0.24 \\ 0.09 & 0.15 & 0.4 & 0.1 & 0.66 \\ 0.1 & 0.1 & 0.43 & 0.29 & 0.56 \\ 0.15 & 0.02 & 0.34 & 0.4 & 0.01 \\ 0.02 & 0.14 & 0.35 & 0.72 & 0.25 \\ 0 & 0 & 0.5 & 0.2 & 0.85 \end{bmatrix}$$

2. Bobot preferensi (*W*) berdasarkan *gain ratio* untuk masing-masing kriteria atau atribut yang sudah ditentukan

$$W = [0.64886 \quad 0.10922 \quad 0.98214 \quad 0.89958 \quad 0.98539]$$

3. Melakukan normalisasi matriks keputusan Z berdasarkan persamaan (2.1) dan (2.2)

$$r_{11} = \frac{0}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0}{0.2} = 0$$

$$r_{12} = \frac{0.08}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0.08}{0.2} = 0.4$$

$$r_{13} = \frac{0.06}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0.06}{0.2} = 0.3$$

$$r_{14} = \frac{0.1}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0.1}{0.2} = 0.5$$

$$r_{15} = \frac{0.08}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.08}{0.2} = 0.4$$

$$r_{16} = \frac{0.09}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.09}{0.2} = 0.45$$

$$r_{17} = \frac{0.1}{\text{Max}\{0;0.08;0.06;0.1;0.08;0.09;0.1;0.15;0.2;0\}} = \frac{0.1}{0.2} = 0.5$$

$$r_{18} = \frac{0.15}{\text{Max}\{0;0.08;0.06;0.1;0.08;0.09;0.1;0.15;0.2;0\}} = \frac{0.15}{0.2} = 0.75$$

$$r_{19} = \frac{0.2}{\text{Max}\{0;0.08;0.06;0.1;0.08;0.09;0.1;0.15;0.2;0\}} = \frac{0.2}{0.2} = 1$$

$$r_{110} = \frac{0}{\text{Max}\{0;0.08;0.06;0.1;0.08;0.09;0.1;0.15;0.2;0\}} = \frac{0}{0.2} = 0 \dots r_n.$$

4. Hasil dari nilai rating kerja ternormalisasi ( $r_{ij}$ ) membentuk matriks ternormalisasi ( $R$ )

$$R = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0.4 & 0.53 & 0.2 & 0.24 & 1 \\ 0.3 & 0.4 & 0.1 & 0.25 & 0.36 \\ 0.5 & 0.66 & 0.3 & 0.66 & 0.33 \\ 0.4 & 0.53 & 0.16 & 1 & 0.26 \\ 0.45 & 1 & 0.8 & 0.102 & 0.73 \\ 0.5 & 0.66 & 0.86 & 0.295 & 0.62 \\ 0.75 & 0.13 & 0.68 & 0.408 & 0.01 \\ 1 & 0.93 & 0.7 & 0.734 & 0.27 \\ 0 & 0 & 1 & 0.204 & 0.94 \end{bmatrix}$$

5. Nilai preferensi untuk setiap alternatif ( $V_i$ ) diperoleh dengan cara menjumlahkan hasil kali antara matriks ternormalisasi ( $R$ ) dengan bobot preferensi ( $W$ ).

$$V_1 = (0 \times 0.64886) + (0 \times 0.10922) + (0 \times 0.98214) + (0 \times 0.98539) + (0 \times 0.84544) = 0$$

$$V_2 = (0.4 \times 0.64886) + (0.53 \times 0.10922) + (0.2 \times 0.98214) + (0.24 \times 0.98539) + (1 \times 0.84544) = 1.71992$$

$$V_3 = (0.3 \times 0.64886) + (0.4 \times 0.10922) + (0.1 \times 0.98214) + (0.25 \times 0.98539) + (0.36 \times 0.84544) = 0.92735$$

$$V_4 = (0.5 \times 0.64886) + (0.66 \times 0.10922) + (0.3 \times 0.98214) + (0.66 \times 0.98539) + (0.33 \times 0.84544) = 1.61701$$

$$V_5 = (0.4 \times 0.64886) + (0.53 \times 0.10922) + (0.16 \times 0.98214) + (1 \times 0.98539) + (0.26 \times 0.84544) = 1.63729$$

$$V_6 = (0.45 \times 0.64886) + (1 \times 0.10922) + (0.8 \times 0.98214) + (0.102 \times 0.98539) + (0.73 \times 0.84544) = 2.00133$$

$$V_7 = (0.5 \times 0.64886) + (0.66 \times 0.10922) + (0.86 \times 0.98214) + (0.295 \times 0.98539) + (0.62 \times 0.84544) = 2.12122$$

$$V_8 = (0.75 \times 0.64886) + (0.13 \times 0.10922) + (0.68 \times 0.98214) + (0.408 \times 0.98539)$$

$$+ (0.01 \times 0.84544) = 1.54719$$

$$V_9 = (1 \times 0.64886) + (0.93 \times 0.10922) + (0.7 \times 0.98214) + (0.734 \times 0.98539) +$$

$$(0.27 \times 0.84544) = 2.37293$$

$$V_{10} = (0 \times 0.64886) + (0 \times 0.10922) + (1 \times 0.98214) + (0.204 \times 0.98539) +$$

$$(0.94 \times 0.84544) = 2.09637$$

Berdasarkan hasil nilai preferensi dari 10 alternatif didapat peringkat alternatif terbaik. Adapun peringkat alternatif terbaik pada 10 *sample* data set *User Knowledge Modelling* dapat dilihat pada tabel 3.3.

**Tabel 3.3** Alternatif Terbaik Berdasarkan Bobot dari Data Set *Sample*

No.	Alternatif	Nilai Preferensi
1.	9	2.37293
2.	7	2.12122
3.	10	2.09637
4.	6	2.00133
5.	2	1.71992
6.	5	1.63729
7.	4	1.61701
8.	8	1.54719
9.	3	0.92735
10.	1	0

Dari 10 alternatif terbaik pada tabel 3.3 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 9 dengan nilai preferensi sebesar 2.37293 dan alternatif terbaik kesepuluh terdapat pada data ke 1 dengan nilai preferensi sebesar 0. Hasil nilai preferensi dari 10 data alternatif berdasarkan bobot dari data set akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan bobot dari data set. Dalam menentukan akurasi,

hasil akar dari jumlah kuadrat nilai preferensi 10 alternatif dikurangi jumlah nilai preferensi 10 alternatif yang dibagi dengan 10 alternatif dan dibagi dengan jumlah alternatif pada data set yaitu 10 dikurangi 1, akan menghasilkan nilai standar deviasi ( $S$ ). Standar deviasi ( $S$ ) dapat dihitung dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan ( $\bar{x}$ ) *mean* dari jumlah nilai preferensi 10 alternatif akan menghasilkan nilai *Relative Standard Deviation (RSD)* berdasarkan persamaan (2.9). Adapun perhitungan standar deviasi dan *Relative Standard Deviation (RSD)* adalah sebagai berikut :

$$S = \sqrt{\frac{30.0378 - \frac{257.301}{10}}{10-1}} = 0.69183$$

$$\bar{x} = \frac{16.04061}{10} = 1.604061$$

$$RSD = \frac{0.69183}{1.604061} \times 100 = 43.13$$

Dalam proses penyelesaian data set *User Knowledge Modelling* dengan jumlah alternatif sebanyak 10 data *sample* maka didapat akurasi sebesar 43.13 % yang diperoleh dari jumlah hasil nilai preferensi 10 alternatif.

Pada pembobotan atribut data set *User Knowledge Modelling* berdasarkan *gain ratio* terdapat beberapa proses yaitu, menghitung nilai *entropy* seluruh data berdasarkan jumlah dari nilai *entropy* setiap *UNS* (very low, low, middle dan high) dari data set menggunakan persamaan (2.4). Selanjutnya, menghitung *information gain* sebagai salah satu atribut seleksi yang digunakan untuk memilih pengujian atribut setiap alternatif pada data set. *Information gain* setiap atribut dapat dihitung berdasarkan pengurangan nilai *entropy* keseluruhan *UNS* dengan jumlah nilai data setiap alternatif dikali dengan nilai *entropy* setiap *UNS* menggunakan persamaan (2.5). Selanjutnya *Split info* dari setiap atribut dihitung berdasarkan jumlah nilai dari setiap alternatif satu atribut menggunakan persamaan (2.6). Kemudian dihitung nilai *gain ratio* untuk setiap atribut dengan membagi nilai *information gain* dengan *split info* menggunakan

persamaan (2.7).. Adapun proses perhitungan bobot dari setiap atribut adalah sebagai berikut :

$$\text{Entropy Very Low} = - (2/10) \times \log_2 (2/10) = 0.46439$$

$$\text{Entropy Low} = - (3/10) \times \log_2 (3/10) = 0.52109$$

$$\text{Entropy Middle} = - (3/10) \times \log_2 (3/10) = 0.52109$$

$$\text{Entropy High} = - (3/10) \times \log_2 (3/10) = 0.52109$$

$$\begin{aligned}\text{Entropy (Seluruh Kelas)} &= (\text{Entropy Very Low}) + (\text{Entropy Low}) + \\ &\quad (\text{Entropy Middle}) + (\text{Entropy High}) \\ &= 0.46439 + 0.52109 + 0.52109 + 0.46439 \\ &= 1.970951\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0)} &= -(1/2) \times \log_2 (1/2) - (0/2) \times \log_2 (0/2) - (0/2) \times \log_2 (0/2) \\ &\quad - (1/2) \times \log_2 (1/2) = 0\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0.08)} &= -(0/2) \times \log_2 (0/2) - (1/2) \times \log_2 (1/2) - (0/2) \times \log_2 (0/2) \\ &\quad - (1/2) \times \log_2 (1/2) = 0\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0.06)} &= -(0/1) \times \log_2 (0/1) - (1/1) \times \log_2 (1/1) - (0/1) \times \log_2 (0/1) \\ &\quad - (0/1) \times \log_2 (0/1) = 0\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0.1)} &= -(0/2) \times \log_2 (0/2) - (0/2) \times \log_2 (0/2) - (2/2) \times \log_2 (2/2) \\ &\quad - (0/2) \times \log_2 (0/2) = 0\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0.09)} &= -(0/1) \times \log_2 (0/1) - (0/1) \times \log_2 (0/1) - (1/1) \times \log_2 (1/1) \\ &\quad - (0/1) \times \log_2 (0/1) = 0\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0.15)} &= -(1/1) \times \log_2 (1/1) - (0/1) \times \log_2 (0/1) - (0/1) \times \log_2 (0/1) \\ &\quad - (0/1) \times \log_2 (0/1) = 0\end{aligned}$$

$$\begin{aligned}\text{Entropy C1}_{(0.2)} &= -(0/1) \times \log_2 (0/1) - (1/1) \times \log_2 (1/1) - (0/1) \times \log_2 (0/1) \\ &\quad - (0/1) \times \log_2 (0/1) = 0\end{aligned}$$

$$\begin{aligned}
Information\ Gain\ (C1) &= \text{Entropy}(\text{Seluruh Kelas}) - \sum_{i=1}^n \frac{|S_i|}{|S|} \times Entropy(S_i) \\
&= 1.970951 - (((2/10) \times 0) - ((2/10) \times 0) - ((1/10) \times 0) - \\
&\quad ((2/10) \times 0) - ((1/10) \times 0) - ((1/10) \times 0) - ((1/10) \times 0)) \\
&= 1.970951
\end{aligned}$$

$$\begin{aligned}
Split\ Info\ (C1) &= -((2/10) \times \text{Log}_2(2/10)) + ((2/10) \times \text{Log}_2(2/10)) + ((1/10) \\
&\quad \times \text{Log}_2(1/10)) + ((2/10) \times \text{Log}_2(2/10)) + ((1/10) \times \text{Log}_2 \\
&\quad (1/10)) + ((1/10) \times \text{Log}_2(1/10)) + ((1/10) \times \text{Log}_2(1/10)) \\
&= 4.55185
\end{aligned}$$

$$\begin{aligned}
Gain\ Ratio\ (C1) &= \frac{\text{Information}\ Gain}{\text{Split}\ Info} \\
&= \frac{1.970951}{4.55185} \\
&= 0.433
\end{aligned}$$

Adapun hasil dari perhitungan bobot dari setiap atribut dapat dilihat pada tabel 3.4.

**Tabel 3.4** Hasil Perhitungan Bobot *Gain Ratio* Setiap Atribut

No.	Atribut	Bobot dari Data Set
1.	<i>STG</i> (C1)	0.433
2.	<i>SCG</i> (C2)	0.618
3.	<i>STR</i> (C3)	0.618
4.	<i>LPR</i> (C4)	0.618
5.	<i>PEG</i> (C5)	1

Berdasarkan tipe 3.4 dapat dilihat bahwa pembobotan atribut berdasarkan *gain ratio* dengan batas nilai atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai atribut pertama (C1) sebesar 0.433, atribut kedua (C2) sebesar 0.618, atribut ketiga sebesar 0.618 dan atribut keempat (C4) sebesar 1. Setelah bobot setiap atribut sudah ditentukan

berdasarkan *gain ratio*, maka selanjutnya dilakukan perhitungan metode *Simple Additive Weighting* (SAW). Adapun proses perhitungan metode *Simple Additive Weighting* (SAW) adalah sebagai berikut :

1. Membuat matriks keputusan Z berukuran  $m \times n$ , dimana  $m = \text{alternatif } (A_i)$  yang akan dipilih dan  $n = \text{kriteria atau atribut } (C_j)$

$$X = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0.08 & 0.08 & 0.1 & 0.24 & 0.9 \\ 0.06 & 0.06 & 0.05 & 0.25 & 0.33 \\ 0.1 & 0.1 & 0.15 & 0.65 & 0.3 \\ 0.08 & 0.08 & 0.08 & 0.98 & 0.24 \\ 0.09 & 0.15 & 0.4 & 0.1 & 0.66 \\ 0.1 & 0.1 & 0.43 & 0.29 & 0.56 \\ 0.15 & 0.02 & 0.34 & 0.4 & 0.01 \\ 0.02 & 0.14 & 0.35 & 0.72 & 0.25 \\ 0 & 0 & 0.5 & 0.2 & 0.85 \end{bmatrix}$$

2. Bobot preferensi ( $W$ ) berdasarkan *Gain Ratio* untuk masing-masing kriteria atau atribut yang sudah ditentukan

$$W = [0.433 \quad 0.618 \quad 0.618 \quad 0.618 \quad 1]$$

3. Melakukan normalisasi matriks keputusan Z berdasarkan persamaan (2.1) dan (2.2)

$$r_{11} = \frac{0}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0}{0.2} = 0$$

$$r_{12} = \frac{0.08}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0.08}{0.2} = 0.4$$

$$r_{13} = \frac{0.06}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0.06}{0.2} = 0.3$$

$$r_{14} = \frac{0.1}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.02; 0\}} = \frac{0.1}{0.2} = 0.5$$

$$r_{15} = \frac{0.08}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.08}{0.2} = 0.4$$

$$r_{16} = \frac{0.09}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.09}{0.2} = 0.45$$

$$r_{17} = \frac{0.1}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.1}{0.2} = 0.5$$

$$r_{18} = \frac{0.15}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.15}{0.2} = 0.75$$

$$r_{19} = \frac{0.2}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0.2}{0.2} = 1$$

$$r_{110} = \frac{0}{\max\{0; 0.08; 0.06; 0.1; 0.08; 0.09; 0.1; 0.15; 0.2; 0\}} = \frac{0}{0.2} = 0 \dots r_n.$$

4. Hasil dari nilai rating kerja ternormalisasi ( $r_{ij}$ ) membentuk matriks ternormalisasi ( $R$ )

$$R = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0.4 & 0.53 & 0.2 & 0.24 & 1 \\ 0.3 & 0.4 & 0.1 & 0.25 & 0.36 \\ 0.5 & 0.66 & 0.3 & 0.66 & 0.33 \\ 0.4 & 0.53 & 0.16 & 1 & 0.26 \\ 0.45 & 1 & 0.8 & 0.102 & 0.73 \\ 0.5 & 0.66 & 0.86 & 0.295 & 0.62 \\ 0.75 & 0.13 & 0.68 & 0.408 & 0.01 \\ 1 & 0.93 & 0.7 & 0.734 & 0.27 \\ 0 & 0 & 1 & 0.204 & 0.94 \end{bmatrix}$$

5. Nilai preferensi untuk setiap alternatif ( $V_i$ ) diperoleh dengan cara menjumlahkan hasil kali antara matriks ternormalisasi ( $R$ ) dengan bobot preferensi ( $W$ ).

$$V_1 = (0 \times 0.433) + (0 \times 0.618) + (0 \times 0.618) + (0 \times 0.618) + (0 \times 1) = 0$$

$$V_2 = (0.4 \times 0.433) + (0.53 \times 0.618) + (0.2 \times 0.618) + (0.24 \times 0.618) + (1 \times 1) = 2.843798$$

$$V_3 = (0.3 \times 0.433) + (0.4 \times 0.618) + (0.1 \times 0.618) + (0.25 \times 0.618) + (0.36 \times 1) = 1.546607$$

$$V_4 = (0.5 \times 0.433) + (0.66 \times 0.618) + (0.3 \times 0.618) + (0.66 \times 0.618) + (0.33 \times 1) = 2.706973$$

$$V_5 = (0.4 \times 0.433) + (0.53 \times 0.618) + (0.16 \times 0.618) + (1 \times 0.618) + (0.26 \times 1) = 2.749901$$

$$V_6 = (0.45 \times 0.433) + (1 \times 0.618) + (0.8 \times 0.618) + (0.102 \times 0.618) + (0.73 \times 1) = 3.444993$$

$$V_7 = (0.5 \times 0.433) + (0.66 \times 0.618) + (0.86 \times 0.618) + (0.295 \times 0.618) + (0.62 \times 1) = 3.508775$$

$$V_8 = (0.75 \times 0.433) + (0.13 \times 0.618) + (0.68 \times 0.618) + (0.408 \times 0.618) + (0.01 \times 1) = 2.284272$$

$$V_9 = (1 \times 0.433) + (0.93 \times 0.618) + (0.7 \times 0.618) + (0.734 \times 0.618) + (0.27 \times 1) = 3.835373$$

$$V_{10} = (0 \times 0.433) + (0 \times 0.618) + (1 \times 0.618) + (0.204 \times 0.618) + (0.94 \times 1) = 3.424163$$

Berdasarkan hasil nilai preferensi dari 10 alternatif didapat peringkat alternatif terbaik. Adapun peringkat alternatif terbaik pada 10 *sample* data set *User Knowledge Modelling* dapat dilihat pada tabel 3.5.

**Tabel 3.5** Alternatif Terbaik Berdasarkan Bobot *Gain Ratio*

No.	Alternatif	Nilai Preferensi
1.	9	3.835373
2.	7	3.508775
3.	6	3.444993
4.	10	3.424163
5.	2	2.843798
6.	5	2.749901
7.	4	2.706973
8.	8	2.284272
9.	3	1.546607
10.	1	0

Dari 10 alternatif terbaik pada tabel 3.5 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 9 dengan nilai preferensi sebesar 3.835373 dan alternatif terbaik kesepuluh terdapat pada data ke 1 dengan nilai preferensi sebesar 0. Hasil nilai preferensi dari 10 data alternatif berdasarkan *gain ratio* akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan *gain ratio*. Dalam menentukan akurasi, hasil akar dari jumlah kuadrat nilai preferensi 10 alternatif dikurangi jumlah nilai preferensi 10 alternatif yang dibagi dengan 10 alternatif dan dibagi dengan jumlah alternatif pada data set yaitu 10 dikurangi 1, akan menghasilkan nilai standar deviasi( $S$ ). Standar deviasi ( $S$ ) dapat dihitung dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan  $(\bar{x})$  *mean* dari jumlah nilai preferensi 10 alternatif akan menghasilkan nilai *Relative Standard Deviation* (*RSD*) berdasarkan persamaan (2.9).

Adapun perhitungan standar deviasi dan *Relative Standard Deviation* (RSD) adalah sebagai berikut :

$$S = \sqrt{\frac{81.2012 - \frac{694.051}{10}}{10-1}} = 1.14485$$

$$\bar{x} = \frac{26.3449}{10} = 2.63449$$

$$RSD = \frac{1.14485}{2.63449} \times 100 = 43.45$$

Dalam proses penyelesaian data set *User Knowledge Modelling* dengan jumlah alternatif sebanyak 10 data *sample* maka didapat akurasi sebesar 43.45 % yang diperoleh dari jumlah hasil nilai preferensi 10 alternatif.

Setelah dilakukan proses perhitungan terhadap 10 data *sample* dengan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan *gain ratio*, maka dapat dilihat hasil akurasi dalam pengambilan keputusan dan menentukan alternatif terbaik. Hasil akurasi dari data alternatif dihitung menggunakan *Relative Standard Deviation* berdasarkan persamaan (2.9). Adapun hasil proses penyelesaian dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan *gain ratio* terhadap pengambilan keputusan dan menentukan alternatif terbaik dapat dilihat pada tabel 3.6.

**Tabel 3.6** Hasil Proses Penyelesaian Data Set *Sample*

Data Set	Pengujian	Jumlah Data	Akurasi (%) Bobot Data Set	Akurasi (%) Bobot Gain Ratio
<i>User Knowledge Modelling</i>	<i>Sample 1</i>	10	43.13	43.45

Berdasarkan tabel 3.6 untuk 10 data *sample* dari data set *User Knowledge Modelling* setelah dilakukan pengujian dengan 10 data alternatif berdasarkan nilai preferensi setiap alternatif menghasilkan tingkat akurasi yang berbeda yaitu, akurasi pada metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot data set sebesar 43.13% dan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot *gain ratio* sebesar 43.45% dan alternatif terbaik pada kedua pembobotan terdapat pada data ke 9 dengan nilai preferensi sebesar 2.37293 dengan menggunakan bobot data set dan 3.835373 dengan menggunakan bobot *gain ratio*. Maka dapat dilihat akurasi pada pembobotan atribut berdasarkan *gain ratio* memiliki akurasi yang lebih baik sebesar 0.32%.

## **BAB 4**

### **HASIL DAN PEMBAHASAN**

Bab ini menjelaskan hasil penelitian dan pembahasan dari kinerja metode *Simple Additive Weighting* (SAW) dengan menggunakan *gain ratio* sebagai dasar pembobotan untuk setiap atribut berdasarkan tingkat akurasi yang dihasilkan. Analisis dilakukan berdasarkan dua pembobotan atribut yang berbeda yaitu, metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* pada proses pengambilan keputusan dan menentukan alternatif terbaik. Pada penelitian ini, proses pengujian diimplementasikan dengan menggunakan RapidMiner dan MATLAB® untuk menpermudah proses perhitungan terhadap seluruh data set yang digunakan.

#### **4.1. Data Penelitian**

Data set yang digunakan pada penelitian ini adalah data set yang berasal dari *UCI Machine Learning Repository*. Data set tersebut direpresentasikan kedalam suatu *file* dengan format *Comma Separated Values* (csv). Data set yang digunakan dalam penelitian ini adalah sebagai berikut :

##### **1. Data set *Cryotherapy***

Data set *Cryotherapy* merupakan data set yang berisi informasi tentang hasil pengobatan kutil dari 90 pasien yang menggunakan metode pengobatan *Cryotherapy*. Beberapa penelitian sebelumnya yang terkait menggunakan data set *Cryotherapy* yaitu penelitian yang dilakukan oleh Khozeimeh, F., Alizadehsani, R., Roshanzamir, M., Khosravi, A., Layegh, P. & Nahavandi, N. (2017) “An expert system for selecting wart treatment method”, pada penelitian yang dilakukan oleh Khozeimeh, F., Jabbari Azad, F., Mahboubi Oskouei, Y., Jafari, M., Tehranian, S., Alizadehsani, R. *et al.* (2017) “Intralesional immunotherapy compared to cryotherapy in the treatment of warts” dan

pada penelitian yang dilakukan oleh Teimoorian, M., Khozeimeh, F., Layegh, P., Alizadehsani, R. (2016) "Intralesional immunotherapy with Candida antigen compared to cryotherapy in the treatment of warts". Adapun informasi data set *Cryotherapy* dapat dilihat pada tabel 4.1.

**Tabel 4.1** Informasi Data Set *Cryotherapy*  
[\(<https://archive.ics.uci.edu/ml/datasets/Cryotherapy+Dataset+>\)](https://archive.ics.uci.edu/ml/datasets/Cryotherapy+Dataset+)

1.	Karakteristik Data Set	Univariate
2.	Karakteristik Atribut	<i>Integer, Real</i>
3.	Tugas Terkait	Klasifikasi
4.	Jumlah Data	90
5.	Jumlah Atribut	7
6.	Nilai yang Hilang	N/A
7.	Area	Life
8.	Tanggal Donasi	2018-01-04
9.	Sumber Data	Name: Fahime Khozeimeh, MD Institution: Faculty of Medicine, Mashhad University of Medical Sciences, Mashhad, Iran. Name: Pouran Layegh, Professor of Dermatology Institution: Mashhad University of Medical Sciences, Mashhad, Iran Name: Roohallah Alizadehsani, PhD student Institution: Institute for Intelligent Systems Research and Innovation (IISRI), Deakin University, Victoria 3217, Australia. Name: Mohamad Roshanzamir, PhD candidate Institution: Electrical and Computer Engineering, Isfahan University of Technology, Isfahan, Iran.

Data set *Cryotherapy* memiliki 6 atribut, 2 hasil perawatan (*result of treatment*) dan 90 data pasien. Adapun informasi atribut data set *Cryotherapy* dapat dilihat pada tabel 4.2.

**Tabel 4.2** Informasi Atribut Data Set *Cryotherapy*

No.	Atribut	Nilai
1.	<i>Sex</i>	{1, 2}
2.	<i>Age</i>	{15, 67}
3.	<i>Time</i>	{0.25, 12}
4.	<i>Number of Warts</i>	{1, 12}
5.	<i>Type</i>	{1, 3}
6.	<i>Area</i>	{4, 750}
7.	<i>Result of Treatment</i>	{0, 1}

## 2. Data Set *Immunotherapy*

Data set *Immunotherapy* merupakan data set yang berisi informasi tentang hasil pengobatan kutil dari 90 pasien yang menggunakan metode pengobatan *Immunotherapy*. Beberapa penelitian sebelumnya yang terkait menggunakan data set *Immunotherapy* yaitu penelitian yang dilakukan oleh Khozeimeh, F., Alizadehsani, R., Roshanzamir, M., Khosravi, A., Layegh, P. & Nahavandi, N. (2017) “An expert system for selecting wart treatment method”, pada penelitian yang dilakukan oleh Khozeimeh, F., Jabbari Azad, F., Mahboubi Oskouei, Y., Jafari, M., Tehranian, S., Alizadehsani, R. et al. (2017) “Intralesional immunotherapy compared to cryotherapy in the treatment of warts”, dan pada penelitian yang dilakukan oleh Teimoorian, M., Khozeimeh, F., Layegh, P., Alizadehsani, R. (2016) “Intralesional immunotherapy with Candida antigen compared to cryotherapy in the treatment of warts”. Adapun informasi data set *Immunotherapy* dapat dilihat pada tabel 4.3.

**Tabel 4.3** Informasi Data Set *Immunotherapy*  
 (<https://archive.ics.uci.edu/ml/datasets/Immunotherapy+Dataset>)

1.	Karakteristik Data Set	Univariate
2.	Karakteristik Atribut	<i>Integer, Real</i>
3.	Tugas Terkait	Klasifikasi
4.	Jumlah Data	90
5.	Jumlah Atribut	8
6.	Nilai yang Hilang	N/A
7.	Area	Life
8.	Tanggal Donasi	2018-01-04
9.	Sumber Data	Name: Fahime Khozeimeh, MD Institution: Faculty of Medicine, Mashhad University of Medical Sciences, Mashhad, Iran. Name: Pouran Layegh, Professor of Dermatology Institution: Mashhad University of Medical Sciences, Mashhad, Iran Name: Roohallah Alizadehsani, PhD student Institution: Institute for Intelligent Systems Research and Innovation (IISRI), Deakin University, Victoria 3217, Australia. Name: Mohamad Roshanzamir, PhD candidate Institution: Electrical and Computer Engineering, Isfahan University of Technology, Isfahan, Iran.

Data set *Immunotherapy* memiliki 7 atribut, 2 hasil perawatan (*result of treatment*) dan 90 data pasien. Adapun informasi atribut data set *Immunotherapy* dapat dilihat pada tabel 4.4.

**Tabel 4.4** Informasi Atribut Data Set *Immunotherapy*

No.	Atribut	Nilai
1.	<i>Sex</i>	{1, 2}
2.	<i>Age</i>	{15, 56}
3.	<i>Time</i>	{1, 12}
4.	<i>Number of Warts</i>	{1, 19}
5.	<i>Type</i>	{1, 3}
6.	<i>Area</i>	{6, 900}
7.	<i>Induration Diameter</i>	{2, 70}
8.	<i>Result of Treatment</i>	{1, 0}

### 3. Data Set *Indian Liver Patient Dataset* (ILPD)

Data set *Indian Liver Patient Dataset* (ILPD) berisi 10 variabel yaitu usia, jenis kelamin, total Bilirubin, Bilirubin langsung, protein total, albumin, rasio A / G, SGPT, SGOT dan Alkphos. Beberapa penelitian sebelumnya yang terkait menggunakan data set *Indian Liver Patient Dataset* (ILPD) yaitu penelitian yang dilakukan oleh Ramana, B. V., Prasad Babu, Prof. M. S. & Venkateswarlu, Prof. N. B (2012) “A Critical Comparative Study of Liver Patients from USA and INDIA: An Exploratory Analysis” dan “A Critical Study of Selected Classification Algorithms for Liver Disease Diagnosis”. Adapun informasi atribut data set *Indian Liver Patient Dataset* (ILPD) dapat dilihat pada tabel 4.5.

**Tabel 4.5** Informasi Data Set ILPD

([https://archive.ics.uci.edu/ml/datasets/ILPD+\(Indian+Liver+Patient+Dataset\)](https://archive.ics.uci.edu/ml/datasets/ILPD+(Indian+Liver+Patient+Dataset)))

1.	Karakteristik Data Set	Multivariate
2.	Karakteristik Atribut	<i>Integer, Real</i>
3.	Tugas Terkait	Klasifikasi
4.	Jumlah Data	583
5.	Jumlah Atribut	10
6.	Nilai yang Hilang	N/A
7.	Area	Life
8.	Tanggal Donasi	2012-05-21
9.	Sumber Data	Name: Bendi Venkata Ramana Institution: Associate Professor, Department of Information Technology, Aditya Institute of Technology and Management, Tekkali - 532201, Andhra Pradesh, India.  Name: Prof. M. Surendra Prasad Babu Institution: Department of Computer Science & Systems Engineering, Andhra University College of Engineering, Visakhapatnam-530 003 Andhra Pradesh, India.  Name : Prof. N. B. Venkateswarlu Institution: Department of Computer Science and Engineering, Aditya Institute of Technology and Management, Tekkali - 532201, Andhra Pradesh, India.

Data set *Indian Liver Patient Dataset* (ILPD) memiliki 10 atribut, 2 *selector* dan 583 data. Adapun informasi atribut data set *Indian Liver Patient Dataset* (ILPD) dapat dilihat pada tabel 4.6.

**Tabel 4.6** Informasi Atribut Data Set ILPD

No.	Atribut	Nilai
1.	<i>Age</i>	{4, 90}
2.	<i>Gender</i>	{Male, Female}
3.	<i>TB</i>	{0.4, 75}
4.	<i>DB</i>	{0.1, 19,7}
5.	<i>Alkphos</i>	{63, 2110}
6.	<i>Sgpt</i>	{10, 2000}
7.	<i>Sgot</i>	{10, 4929}
8.	<i>TP</i>	{2.7, 9.6}
9.	<i>ALB</i>	{0.9, 5.5}
10.	<i>A/G</i>	{0.3, 2.8}
11.	<i>Selector</i>	{1, 2}

#### 4. Data Set *User Knowledge Modelling*

Data set *User Knowledge Modelling* merupakan data set nyata tentang status pengetahuan siswa tentang subjek Mesin DC Listrik. Data set telah diperoleh dari Ph.D. dan Tesis. Beberapa penelitian sebelumnya yang terkait menggunakan data set *User Knowledge Modelling* yaitu penelitian yang dilakukan oleh Kahraman, H. T., Sagiroglu, S. & Colak, I (2013) “Developing intuitive knowledge classifier and modelling of users' domain dependent data in web” dan pada penelitian yang dilakukan oleh Kahraman, H. T. (2009) “Designing and Application of Web-Based Adaptive Intelligent Education System”. Adapun informasi data set *User Knowledge Modelling* dapat dilihat pada tabel 4.7.

**Tabel 4.7** Informasi Data Set *User Knowledge Modelling*  
[\(<https://archive.ics.uci.edu/ml/datasets/User+Knowledge+Modelling>\)](https://archive.ics.uci.edu/ml/datasets/User+Knowledge+Modelling)

1.	Karakteristik Data Set	Multivariate
2.	Karakteristik Atribut	<i>Integer</i>
3.	Tugas Terkait	Klasifikasi, Clustering
4.	Jumlah Data	403
5.	Jumlah Atribut	5
6.	Nilai yang Hilang	N/A
7.	Area	Computer
8.	Tanggal Donasi	2013-06-26
9.	Sumber Data	Creators: Hamdi Tolga Kahraman Institution: Faculty of Technology, Department of Software Engineering, Karadeniz Technical University, Trabzon, Turkiye Creators: Ilhami Colak Institution: Faculty of Technology, Department of Electrical and Electronics Engineering, Gazi University, Ankara, Turkiye Creators: Seref Sagiroglu Institution: Faculty of Technology, Department of Computer Engineering, Gazi University, Ankara, Turkiye.

Data set *User Knowledge Modelling* memiliki 5 atribut, 4 UNS dan 403 data. Adapun informasi atribut data set *User Knowledge Modelling* dapat dilihat pada tabel 4.8.

**Tabel 4.8** Informasi Atribut Data Set *User Knowledge Modelling*

No.	Atribut	Nilai
1.	<i>STG</i>	{0, 0.99}
2.	<i>SCG</i>	{0, 0.9}
3.	<i>STR</i>	{0, 0.95}
4.	<i>LPR</i>	{0, 0.99}
5.	<i>PEG</i>	{0, 0.99}
6.	<i>UNS</i>	{Very Low, Low, Middle, High}

## 4.2. Pembobotan Atribut

Pembobotan atribut pada metode *Simple Additive Weighting* (SAW) menggunakan pembobotan berdasarkan bobot dari data set dan pembobotan berdasarkan *gain ratio*. Pembobotan untuk setiap atribut akan mempengaruhi hasil dari nilai preferensi setiap alternatif metode *Simple Additive Weighting* (SAW) dan tingkat akurasi dalam pengambilan keputusan dan nilai alternatif terbaik.

### 4.2.1. Pembobotan Data Set *Cryotherapy*

Pada data set *Cryotherapy*, dalam menentukan bobot atribut menggunakan pembobotan berdasarkan bobot dari data set dan pembobotan berdasarkan *gain ratio*. Pada pembobotan atribut data set *Cryotherapy* berdasarkan bobot dari data set diperoleh dari jurnal “An Expert System for Selecting Wart Treatment Method” (Khozeimeh *et al*, 2017) berdasarkan persetujuan sumber data set yaitu Fahime Khozeimeh, MD via email (fahime.khozeime@yahoo.com). Adapun pembobotan atribut berdasarkan dari data set dapat dilihat pada tabel 4.9.

**Tabel 4.9** Pembobotan Atribut Berdasarkan dari Data Set *Cryotherapy*

No.	Atribut	Bobot dari Data Set
1.	<i>Sex</i> (C1)	0.03
2.	<i>Age</i> (C2)	1
3.	<i>Time</i> (C3)	0.917
4.	<i>Number of Warts</i> (C4)	0.107
5.	<i>Type</i> (C5)	0.841
6.	<i>Area</i> (C6)	0.653

Berdasarkan tabel 4.9 dapat dilihat untuk pembobotan atribut berdasarkan dari data set *Cryotherapy* sebanyak 90 data dengan batas nilai bobot atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai atribut *sex* (C1) sebesar 0.03, atribut *age* (C2) sebesar 1, atribut *time* (C3) sebesar 0.917, atribut *number of warts* (C4) sebesar 0.107, atribut *type* (C5) sebesar 0.841 dan atribut *area* (C6) sebesar 0.653. Pembobotan atribut berdasarkan dari data set digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

Pada pembobotan atribut data set *Cryotherapy* berdasarkan *gain ratio* terdapat beberapa proses yaitu, menghitung nilai *entropy* seluruh data berdasarkan jumlah dari nilai *entropy* setiap *result of treatment* (0 dan 1) dari data set menggunakan persamaan (2.4). Selanjutnya, menghitung *information gain* sebagai salah satu atribut seleksi yang digunakan untuk memilih pengujian atribut setiap alternatif pada data set. *Information gain* setiap atribut dapat dihitung berdasarkan pengurangan nilai *entropy* keseluruhan *result of treatment* dengan jumlah nilai data setiap alternatif dikali dengan nilai *entropy* setiap *result of treatment* menggunakan persamaan (2.5). Selanjutnya *Split info* dari setiap atribut dihitung berdasarkan jumlah nilai dari setiap alternatif satu atribut menggunakan persamaan (2.6). Kemudian dihitung nilai *gain ratio* untuk setiap atribut dengan membagi nilai *information gain* dengan *split info* menggunakan persamaan (2.7). Adapun hasil dari pembobotan atribut menggunakan *gain ratio* dapat dilihat pada tabel 4.10.

**Tabel 4.10** Pembobotan Atribut Data *Cryotherapy* Berdasarkan *Gain Ratio*

No.	Atribut	Bobot dari <i>Gain Ratio</i>
1.	<i>Sex</i> (C1)	0.00537
2.	<i>Age</i> (C2)	0.28036
3.	<i>Time</i> (C3)	0.41612
4.	<i>Number of Warts</i> (C4)	0.04193
5.	<i>Type</i> (C5)	0.22351
6.	<i>Area</i> (C6)	0.17833

Berdasarkan tabel 4.10 dapat dilihat untuk pembobotan atribut data set *Cryotherapy* sebanyak 90 data berdasarkan *gain ratio* dengan batas nilai bobot atribut terendah 0 dan tertinggi 0.5 yaitu, untuk nilai bobot atribut *sex* (C1) sebesar 0.00537, bobot atribut *age* (C2) 0.28036, bobot atribut *time* (C3) 0.41612, bobot atribut *number of warts* (C4) sebesar 0.04193, bobot atribut *type* (C5) sebesar 0.22351 dan bobot atribut *area* (C6) sebesar 0.17833. Hasil pembobotan atribut berdasarkan *gain ratio* digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

#### 4.2.2. Pembobotan Data Set *Immunotherapy*

Pada data set *Immunotherapy*, dalam menentukan bobot atribut menggunakan pembobotan berdasarkan bobot dari data set dan pembobotan berdasarkan *gain ratio*. Pada pembobotan atribut data set *Immunotherapy* berdasarkan bobot dari data set diperoleh dari jurnal “An Expert System for Selecting Wart Treatment Method” (Khozeimeh *et al*, 2017) berdasarkan persetujuan sumber data set yaitu Fahime Khozeimeh, MD via email (fahime.khozeime@yahoo.com). Adapun pembobotan atribut berdasarkan dari data set dapat dilihat pada tabel 4.11.

**Tabel 4.11** Pembobotan Atribut Berdasarkan dari Data Set *Immunotherapy*

No.	Atribut	Bobot dari Data Set
1.	<i>Sex</i> (C1)	0.052
2.	<i>Age</i> (C2)	0.596
3.	<i>Time</i> (C3)	1
4.	<i>Number of Warts</i> (C4)	0.032
5.	<i>Type</i> (C5)	0.579
6.	<i>Area</i> (C6)	0.462
7.	<i>Induration Diameter</i> (C7)	0.769

Berdasarkan tabel 4.11 dapat dilihat untuk pembobotan atribut berdasarkan dari data set *Immunotherapy* sebanyak 90 data dengan batas nilai bobot atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai atribut *sex* (C1) sebesar 0.052, atribut *age* (C2) sebesar 0.596, atribut *time* (C3) sebesar 1, atribut *number of warts* (C4) sebesar 0.032, atribut *type* (C5) sebesar 0.579, atribut *area* (C6) sebesar 0.462 dan atribut *induration diameter* (C7) sebesar 0.769. Pembobotan atribut berdasarkan dari data set digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

Pada pembobotan atribut data set *Immunotherapy* berdasarkan *gain ratio* terdapat beberapa proses yaitu, menghitung nilai *entropy* seluruh data berdasarkan jumlah dari nilai *entropy* setiap *result of treatment* (0 dan 1) dari data set menggunakan persamaan (2.4). Selanjutnya, menghitung *information gain* sebagai salah satu atribut seleksi yang digunakan untuk memilih pengujian atribut setiap alternatif pada data set. *Information gain* setiap atribut dapat dihitung berdasarkan pengurangan nilai *entropy* keseluruhan *result of treatment* dengan jumlah nilai data setiap alternatif dikali dengan nilai *entropy* setiap *result of treatment* menggunakan persamaan (2.5). Selanjutnya *Split info* dari setiap atribut dihitung berdasarkan jumlah nilai dari setiap alternatif satu atribut menggunakan persamaan (2.6). Kemudian dihitung nilai *gain ratio* untuk setiap atribut dengan membagi nilai *information gain* dengan *split info* menggunakan persamaan (2.7). Adapun hasil dari pembobotan atribut menggunakan *gain ratio* dapat dilihat pada tabel 4.12.

**Tabel 4.12** Pembobotan Atribut Data *Immunotherapy* Berdasarkan *Gain Ratio*

No.	Atribut	Bobot dari <i>Gain Ratio</i>
1.	<i>Sex</i> (C1)	2.56892
2.	<i>Age</i> (C2)	0.28695
3.	<i>Time</i> (C3)	0.36994
4.	<i>Number of Warts</i> (C4)	0.05007
5.	<i>Type</i> (C5)	0.00837
6.	<i>Area</i> (C6)	0.08070
7.	<i>Induration Diameter</i> (C7)	0.09717

Berdasarkan tabel 4.12 dapat dilihat untuk pembobotan atribut data set *Cryotherapy* sebanyak 90 data berdasarkan *gain ratio* dengan batas nilai bobot atribut terendah 0 dan tertinggi 3 yaitu, untuk nilai bobot atribut *sex* (C1) sebesar 2.568925012439287E-4, bobot atribut *age* (C2) 0.2869525810043716, bobot atribut *time* (C3) 0.36994852260025585, bobot atribut *number of warts* (C4) sebesar 0.05007938622150365, bobot atribut *type* (C5) sebesar 0.00837226083025111, bobot atribut *area* (C6) sebesar 0.08070657713255312 dan bobot atribut *induration diameter* (C7) sebesar 0.09717967400530042. Hasil pembobotan atribut berdasarkan *gain ratio* digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

#### 4.2.3. Pembobotan Data Set Indian Liver Patient Dataset (ILPD)

Pada data set *Indian Liver Patient Dataset* (ILPD), dalam menentukan bobot atribut menggunakan pembobotan berdasarkan bobot dari data set dan pembobotan berdasarkan *gain ratio*. Pada pembobotan atribut data set *Indian Liver Patient Dataset* (ILPD) berdasarkan bobot dari data set diperoleh dari nilai peringkat kepentingan setiap atribut berdasarkan sumber data set yaitu Bendi Venkata Ramana via email (ramana.bendi@gmail.com). Adapun pembobotan atribut berdasarkan dari data set dapat dilihat pada tabel 4.13.

**Tabel 4.13** Pembobotan Atribut Berdasarkan dari Data Set ILPD

No.	Atribut	Bobot dari Data Set
1.	<i>Age</i> (C1)	7
2.	<i>Gender</i> (C2)	6
3.	<i>TB</i> (C3)	1
4.	<i>DB</i> (C4)	2
5.	<i>Alkphos</i> (C5)	10
6.	<i>Sgpt</i> (C6)	5
7.	<i>Sgot</i> (C7)	4
8.	<i>TP</i> (C8)	8
9.	<i>ALB</i> (C9)	3
10.	<i>A/G</i> (C10)	9

Berdasarkan tabel 4.13 dapat dilihat untuk pembobotan atribut berdasarkan dari data set *Indian Liver Patient Dataset* (ILPD) sebanyak 583 data dengan batas nilai bobot atribut terendah 0 dan tertinggi 10 yaitu, untuk nilai atribut *age* (C1) sebesar 7, atribut *gender* (C2) sebesar 6, atribut *TB* (C3) sebesar 1, atribut *DB* (C4) sebesar 2, atribut *alkphos* (C5) sebesar 10, atribut *sgpt* (C6) sebesar 5, atribut *sgot* (C7) sebesar 4, atribut *TP* (C8) sebesar 8, atribut *ALB* (C9) sebesar 3 dan atribut *A/G* (C10) sebesar 9. Pembobotan atribut berdasarkan dari data set digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

Pada pembobotan atribut data set *Indian Liver Patient Dataset* (ILPD) berdasarkan *gain ratio* terdapat beberapa proses yaitu, menghitung nilai *entropy* seluruh data berdasarkan jumlah dari nilai *entropy* setiap *selector* (1 dan 2) dari data set menggunakan persamaan (2.4). Selanjutnya, menghitung *information gain* sebagai salah satu atribut seleksi yang digunakan untuk memilih pengujian atribut setiap alternatif pada data set. *Information gain* setiap atribut dapat dihitung berdasarkan pengurangan nilai *entropy* keseluruhan *selector* dengan jumlah nilai data setiap alternatif dikali dengan nilai *entropy* setiap *selector* menggunakan persamaan (2.5). Selanjutnya *Split info* dari setiap atribut dihitung berdasarkan jumlah nilai dari setiap

alternatif satu atribut menggunakan persamaan (2.6). Kemudian dihitung nilai *gain ratio* untuk setiap atribut dengan membagi nilai *information gain* dengan *split info* menggunakan persamaan (2.7). Adapun hasil dari pembobotan atribut menggunakan *gain ratio* dapat dilihat pada tabel 4.14.

**Tabel 4.14** Pembobotan Atribut Data ILPD Berdasarkan *Gain Ratio*

No.	Atribut	Bobot dari <i>Gain Ratio</i>
1.	<i>Age</i> (C1)	0.88124
2.	<i>Gender</i> (C2)	0
3.	<i>TB</i> (C3)	0.48605
4.	<i>DB</i> (C4)	0.49604
5.	<i>Alkphos</i> (C5)	0.27114
6.	<i>Sgpt</i> (C6)	1
7.	<i>Sgot</i> (C7)	0.74294
8.	<i>TP</i> (C8)	0.24910
9.	<i>ALB</i> (C9)	0.21769
10.	<i>A/G</i> (C10)	0.24003

Berdasarkan tabel 4.14 dapat dilihat untuk pembobotan atribut data set *Indian Liver Patient Dataset* (ILPD) sebanyak 583 data berdasarkan *gain ratio* dengan batas nilai bobot atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai bobot atribut *age* (C1) sebesar 0.88124, bobot atribut *gender* (C2) 0, bobot atribut *TB* (C3) 0.48605, bobot atribut *DB* (C4) sebesar 0.49604, bobot atribut *alkphos* (C5) sebesar 0.27114, bobot atribut *sgpt* (C6) sebesar 1, bobot atribut *sgot* (C7) sebesar 0.74294, bobot atribut *TP* (C8) sebesar 0.24910, bobot atribut *ALB* (C9) sebesar 0.21769 dan bobot atribut *A/G* (C10) sebesar 0.24003. Hasil pembobotan atribut berdasarkan *gain ratio* digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

#### 4.2.4. Pembobotan Data Set User Knowledge Modelling

Pada data set *User Knowledge Modelling*, dalam menentukan bobot atribut menggunakan pembobotan berdasarkan bobot dari data set dan pembobotan berdasarkan *gain ratio*. Pada pembobotan atribut data set *User Knowledge Modelling* berdasarkan bobot dari data set diperoleh dari jurnal “The Development of Intuitive Knowledge Classifier and The Modelling of Domain Dependent Data” (Kahraman *et al*, 2013) berdasarkan persetujuan sumber data set yaitu H. Tolga Kahraman via email (htolgakahraman@yahoo.com). Adapun pembobotan atribut berdasarkan dari data set dapat dilihat pada tabel 4.15.

**Tabel 4.15** Pembobotan Atribut Berdasarkan dari Data Set *User Knowledge Modelling*

No.	Atribut	Bobot dari Data Set
1.	<i>STG</i> (C1)	0.19251
2.	<i>SCG</i> (C2)	0.03063
3.	<i>STR</i> (C3)	0.13285
4.	<i>LPR</i> (C4)	0.22119
5.	<i>PEG</i> (C5)	0.84544

Berdasarkan tabel 4.15 dapat dilihat untuk pembobotan atribut berdasarkan dari data set *User Knowledge Modelling* sebanyak 258 data dengan batas nilai bobot atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai atribut *STG* (C1) sebesar 0.19251, atribut *SCG* (C2) sebesar 0.03063, atribut *STR* (C3) sebesar 0.13285, atribut *LPR* (C4) sebesar 0.22119 dan atribut *PEG* (C5) sebesar 0.84544. Pembobotan atribut berdasarkan dari data set digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

Pada pembobotan atribut data set *User Knowledge Modelling* berdasarkan *gain ratio* terdapat beberapa proses yaitu, menghitung nilai *entropy* seluruh data berdasarkan jumlah dari nilai *entropy* setiap *UNS* (very low, low, middle dan high) dari data set menggunakan persamaan (2.4). Selanjutnya, menghitung *information gain* sebagai

salah satu atribut seleksi yang digunakan untuk memilih pengujian atribut setiap alternatif pada data set. *Information gain* setiap atribut dapat dihitung berdasarkan pengurangan nilai *entropy* keseluruhan *UNS* dengan jumlah nilai data setiap alternatif dikali dengan nilai *entropy* setiap *UNS* menggunakan persamaan (2.5). Selanjutnya *Split info* dari setiap atribut dihitung berdasarkan jumlah nilai dari setiap alternatif satu atribut menggunakan persamaan (2.6). Kemudian dihitung nilai *gain ratio* untuk setiap atribut dengan membagi nilai *information gain* dengan *split info* menggunakan persamaan (2.7). Adapun hasil dari pembobotan atribut menggunakan *gain ratio* dapat dilihat pada tabel 4.16.

**Tabel 4.16** Pembobotan Atribut Data *User Knowledge Modelling* Berdasarkan *Gain Ratio*

No.	Atribut	Bobot dari <i>Gain Ratio</i>
1.	<i>STG</i> (C1)	0.10241
2.	<i>SCG</i> (C2)	0
3.	<i>STR</i> (C3)	0.19456
4.	<i>LPR</i> (C4)	0.19456
5.	<i>PEG</i> (C5)	1

Berdasarkan tabel 4.16 dapat dilihat untuk pembobotan atribut data set *User Knowledge Modelling* sebanyak 258 data berdasarkan *gain ratio* dengan batas nilai bobot atribut terendah 0 dan tertinggi 1 yaitu, untuk nilai bobot atribut *STG* (C1) sebesar 0.10241, bobot atribut *SCG* (C2) 0, bobot atribut *STR* (C3) 0.19456, bobot atribut *LPR* (C4) sebesar 0.19456 dan bobot atribut *PEG* (C5) sebesar 1. Hasil pembobotan atribut berdasarkan *gain ratio* digunakan dalam proses perhitungan metode *Simple Additive Weighting* (SAW).

### **4.3. Pengujian Data**

Pada proses pengujian data set dilakukan proses perhitungan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan *gain ratio* untuk memperoleh nilai preferensi dari setiap alternatif dengan cara menjumlahkan hasil kali antara matriks ternormalisasi dengan bobot preferensi. Bobot preferensi adalah bobot yang telah ditentukan berdasarkan bobot dari data set dan berdasarkan bobot *gain ratio*. Nilai preferensi pada setiap alternatif dari data set menentukan nilai akurasi dari metode *Simple Additive Weighting* (SAW) dalam pengambilan keputusan dan menentukan alternatif terbaik.

#### *4.3.1. Pengujian Data Set Cryotherapy*

Untuk melakukan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set dan bobot *gain ratio*, tentunya harus dilakukan proses perhitungan untuk mendapatkan nilai preferensi setiap atribut. Data yang digunakan untuk proses pengujian adalah data set *Cryotherapy*. Adapun proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set yaitu, membuat matriks keputusan Z berukuran  $m \times n$  yang terdiri dari 90 alternatif ( $m$ ) dari data pasien yang akan dipilih dan 6 atribut ( $n$ ) yaitu, *sex* (C1), *age* (C2), *time* (C3), *number of warts* (C4), *type* (C5), dan *area* (C6). Matriks keputusan Z dinormalisasi berdasarkan persamaan (2.1) dan (2.2). Hasil normalisasi matriks keputusan Z dapat dilihat pada lampiran I. Hasil dari nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot dari data set *Cryotherapy* pada tabel 4.9 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 90 alternatif. Berdasarkan hasil nilai preferensi dari 90 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set *Cryotherapy* dapat dilihat pada tabel 4.17.

**Tabel 4.17** Alternatif Terbaik Berdasarkan Bobot dari Data Set *Cryotherapy*

No.	Alternatif	Nilai Preferensi
1.	64	3.0256
2.	34	2.9543
3.	4	2.9469
4.	35	2.9316
5.	63	2.4938
6.	33	2.4839
7.	28	2.4420
8.	40	2.4200
9.	26	2.4049
10.	86	2.4049

Dari 10 alternatif terbaik pada tabel 4.17 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 64 dengan nilai preferensi sebesar 3.0256 dan alternatif terbaik kesepuluh terdapat pada data ke 86 dengan nilai preferensi sebesar 2.4049. Hasil nilai preferensi dari 90 alternatif berdasarkan bobot dari data set akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan bobot dari data set *Cryotherapy*. Dalam menentukan akurasi, hasil akar dari jumlah kuadrat nilai preferensi 90 alternatif dikurangi jumlah nilai preferensi 90 alternatif yang dibagi dengan 90 alternatif dan dibagi dengan jumlah alternatif pada data set yaitu 90 dikurangi 1, akan menghasilkan nilai standar deviasi. Standar deviasi dapat dihitung dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 90 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set *Cryotherapy* dihitung berdasarkan persamaan (2.9). Dalam pengujian data set *Cryotherapy* dengan jumlah alternatif sebanyak 90 data maka didapat akurasi sebesar 34.54 % yang diperoleh dari jumlah hasil nilai preferensi 90 alternatif.

Pada proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan *gain ratio* sama dengan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set. Namun yang membedakan pada proses pengujian yaitu pada hasil nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot *gain ratio* pada tabel 4.10 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 90 alternatif. Berdasarkan hasil nilai preferensi dari 90 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set *Cryotherapy* berdasarkan pembobotan *gain ratio* dapat dilihat pada tabel 4.18.

**Tabel 4.18** Alternatif Terbaik Data Set *Cryotherapy* Berdasarkan Bobot *Gain Ratio*

No.	Alternatif	Nilai Preferensi
1.	64	0.9992
2.	35	0.9773
3.	34	0.9712
4.	4	0.9704
5.	28	0.8327
6.	40	0.8238
7.	26	0.8204
8.	86	0.8204
9.	63	0.8129
10.	33	0.8087

Dari 10 alternatif terbaik pada tabel 4.18 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 64 dengan nilai preferensi sebesar 0.9992 dan alternatif terbaik kesepuluh terdapat pada data ke 86 dengan nilai preferensi sebesar 0.8087. Hasil nilai preferensi dari 90 alternatif berdasarkan bobot *gain ratio* akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio*. Dalam proses menentukan

akurasi, sama dengan pembobotan atribut berdasarkan data set yaitu menghitung nilai standar deviasi dari 90 alternatif data dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 90 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* pada data set *Cryotherapy* dihitung berdasarkan persamaan (2.9). Dalam pengujian data set *Cryotherapy* dengan jumlah alternatif sebanyak 90 data maka didapat akurasi sebesar 34.04 % diperoleh dari jumlah hasil nilai preferensi 90 alternatif.

#### 4.3.2. Pengujian Data Set *Immunotherapy*

Untuk melakukan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set dan bobot *gain ratio*, tentunya harus dilakukan proses perhitungan untuk mendapatkan nilai preferensi setiap atribut. Data yang digunakan untuk proses pengujian adalah data set *Immunotherapy*. Adapun proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set yaitu, membuat matriks keputusan Z berukuran  $m \times n$  yang terdiri dari 90 alternatif ( $m$ ) dari data pasien yang akan dipilih dan 7 atribut ( $n$ ) yaitu, *sex* (C1), *age* (C2), *time* (C3), *number of warts* (C4), *type* (C5), *area* (C6) dan *induration diameter* (C8). Matriks keputusan Z dinormalisasi berdasarkan persamaan (2.1) dan (2.2). Hasil normalisasi matriks keputusan Z dapat dilihat pada lampiran II. Hasil dari nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot dari data set *Immunotherapy* pada tabel 4.11 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 90 alternatif. Berdasarkan hasil nilai preferensi dari 90 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set *Immunotherapy* dapat dilihat pada tabel 4.19.

**Tabel 4.19** Alternatif Terbaik Berdasarkan Bobot dari Data Set *Immunotherapy*

No.	Alternatif	Nilai Preferensi
1.	59	2.3972
2.	2	2.2490
3.	29	2.1475
4.	89	2.1461
5.	58	2.1271
6.	57	2.0799
7.	10	2.0546
8.	76	2.0072
9.	88	1.9950
10.	87	1.9780

Dari 10 alternatif terbaik pada tabel 4.19 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 59 dengan nilai preferensi sebesar 2.3972 dan alternatif terbaik kesepuluh terdapat pada data ke 87 dengan nilai preferensi sebesar 1.9780. Hasil nilai preferensi dari 90 alternatif berdasarkan bobot dari data set akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan bobot dari data set *Immunotherapy*. Dalam menentukan akurasi, hasil akar dari jumlah kuadrat nilai preferensi 90 alternatif dikurangi jumlah nilai preferensi 90 alternatif yang dibagi dengan 90 alternatif dan dibagi dengan jumlah alternatif pada data set yaitu 90 dikurangi 1, akan menghasilkan nilai standar deviasi. Standar deviasi dapat dihitung dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 90 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set *Immunotherapy* dihitung berdasarkan persamaan (2.9). Dalam pengujian data set *Immunotherapy* dengan jumlah alternatif sebanyak 90 data maka didapat akurasi sebesar 23.77 % yang diperoleh dari jumlah hasil nilai preferensi 90 alternatif.

Pada proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan *gain ratio* sama dengan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set. Namun yang membedakan pada proses pengujian yaitu pada hasil nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot *gain ratio* pada tabel 4.12 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 90 alternatif. Berdasarkan hasil nilai preferensi dari 90 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set *Immunotherapy* berdasarkan pembobotan *gain ratio* dapat dilihat pada tabel 4.20.

**Tabel 4.20** Alternatif Terbaik Data Set *Immunotherapy* Berdasarkan Bobot *Gain Ratio*

No.	Alternatif	Nilai Preferensi
1.	59	0.7429
2.	88	0.6466
3.	79	0.6360
4.	29	0.6351
5.	89	0.6338
6.	58	0.6257
7.	33	0.6226
8.	50	0.6206
9.	76	0.6101
10.	70	0.6084

Dari 10 alternatif terbaik pada tabel 4.20 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 59 dengan nilai preferensi sebesar 0.7429 dan alternatif terbaik kesepuluh terdapat pada data ke 70 dengan nilai preferensi sebesar 0.6084. Hasil nilai preferensi dari 90 alternatif berdasarkan bobot *gain ratio* akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan

menggunakan pembobotan atribut berdasarkan *gain ratio*. Dalam proses menentukan akurasi, sama dengan pembobotan atribut berdasarkan data set yaitu menghitung nilai standar deviasi dari 90 alternatif data dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 90 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* pada data set *Immunotherapy* dihitung berdasarkan persamaan (2.9). Dalam pengujian data set *Immunotherapy* dengan jumlah alternatif sebanyak 90 data maka didapat akurasi sebesar 28.38 % diperoleh dari jumlah hasil nilai preferensi 90 alternatif.

#### 4.3.3. Pengujian Data Set Indian Liver Patient Dataset (ILPD)

Untuk melakukan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set dan bobot *gain ratio*, tentunya harus dilakukan proses perhitungan untuk mendapatkan nilai preferensi setiap atribut. Data yang digunakan untuk proses pengujian adalah data set ILPD. Adapun proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set yaitu, membuat matriks keputusan Z berukuran  $m \times n$  yang terdiri dari 583 alternatif ( $m$ ) dari data pasien yang akan dipilih dan 10 atribut ( $n$ ) yaitu, *age* (C1), *gender* (C2), *TB* (C3), *DB* (C4), *alkphos* (C5), *sgpt* (C6), *sgot* (C7), *TP* (C8), *ALB* (C9) dan *A/G* (C10). Matriks keputusan Z dinormalisasi berdasarkan persamaan (2.1) dan (2.2). Hasil normalisasi matriks keputusan Z dapat dilihat pada lampiran III. Hasil dari nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot dari data set ILPD pada tabel 4.13 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 583 alternatif. Berdasarkan hasil nilai preferensi dari 583 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set ILPD dapat dilihat pada tabel 4.21.

**Tabel 4.21** Alternatif Terbaik Berdasarkan Bobot dari Data Set ILPD

No.	Alternatif	Nilai Preferensi
1.	136	32.9878
2.	576	29.0237
3.	234	28.6236
4.	118	28.3264
5.	430	27.7188
6.	549	27.6264
7.	169	27.4177
8.	373	27.1086
9.	28	27.0979
10.	453	26.5670

Dari 10 alternatif terbaik pada tabel 4.21 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 136 dengan nilai preferensi sebesar 32.9878 dan alternatif terbaik kesepuluh terdapat pada data ke 453 dengan nilai preferensi sebesar 26.5670. Hasil nilai preferensi dari 583 alternatif berdasarkan bobot dari data set akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan bobot dari data set *Indian Liver Patient Dataset* (ILPD). Dalam menentukan akurasi, hasil akar dari jumlah kuadrat nilai preferensi 583 alternatif dikurangi jumlah nilai preferensi 583 alternatif yang dibagi dengan 583 alternatif dan dibagi dengan jumlah alternatif pada data set yaitu 583 dikurangi 1, akan menghasilkan nilai standar deviasi. Standar deviasi dapat dihitung dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 583 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set ILPD dihitung berdasarkan persamaan (2.9). Dalam pengujian data set ILPD dengan jumlah alternatif sebanyak 583 data maka didapat akurasi sebesar 17.5 % yang diperoleh dari jumlah hasil nilai preferensi 583 alternatif.

Pada proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan *gain ratio* sama dengan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set. Namun yang membedakan pada proses pengujian yaitu pada hasil nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot *gain ratio* pada tabel 4.14 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 583 alternatif. Berdasarkan hasil nilai preferensi dari 583 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set ILPD berdasarkan pembobotan *gain ratio* dapat dilihat pada tabel 4.22.

**Tabel 4.22** Alternatif Terbaik Data Set ILPD Berdasarkan Bobot *Gain Ratio*

No.	Alternatif	Nilai Preferensi
1.	136	2.6906
2.	118	2.4107
3.	28	1.8956
4.	119	1.8866
5.	448	1.8095
6.	120	1.7782
7.	48	1.7450
8.	208	1.6415
9.	169	1.5956
10.	200	1.5494

Dari 10 alternatif terbaik pada tabel 4.22 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 136 dengan nilai preferensi sebesar 2.6906 dan alternatif terbaik kesepuluh terdapat pada data ke 200 dengan nilai preferensi sebesar 1.5494. Hasil nilai preferensi dari 583 alternatif berdasarkan bobot *gain ratio* akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio*. Dalam proses menentukan

akurasi, sama dengan pembobotan atribut berdasarkan data set yaitu menghitung nilai standar deviasi dari 583 alternatif data dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 583 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* pada data set *Indian Liver Patient Dataset* (ILPD) dihitung berdasarkan persamaan (2.9). Dalam pengujian data set ILPD dengan jumlah alternatif sebanyak 583 data maka didapat akurasi sebesar 24.79 % diperoleh dari jumlah hasil nilai preferensi 583 alternatif.

#### 4.3.4. Pengujian Data Set User Knowledge Modelling

Untuk melakukan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set dan bobot *gain ratio*, tentunya harus dilakukan proses perhitungan untuk mendapatkan nilai preferensi setiap atribut. Data yang digunakan untuk proses pengujian adalah data set *User Knowledge Modelling*. Adapun proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set yaitu, membuat matriks keputusan Z berukuran  $m \times n$  yang terdiri dari 258 alternatif ( $m$ ) dari data pasien yang akan dipilih dan 5 atribut ( $n$ ) yaitu, *STG* (C1), *SCG* (C2), *STR* (C3), *LPR* (C4) dan *PEG* (C5). Matriks keputusan Z dinormalisasi berdasarkan persamaan (2.1) dan (2.2). Hasil normalisasi matriks keputusan Z dapat dilihat pada lampiran IV. Hasil dari nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot dari data set *User Knowledge Modelling* pada tabel 4.15 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 258 alternatif. Berdasarkan hasil nilai preferensi dari 258 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set *User Knowledge Modelling* dapat dilihat pada tabel 4.23.

**Tabel 4.23** Alternatif Terbaik Berdasarkan Bobot dari Data Set *User Knowledge Modelling*

No.	Alternatif	Nilai Preferensi
1.	242	1.2426
2.	246	1.2319
3.	249	1.2281
4.	258	1.1323
5.	49	1.1227
6.	158	1.1133
7.	210	1.0912
8.	205	1.0809
9.	173	1.0704
10.	187	1.0655

Dari 10 alternatif terbaik pada tabel 4.23 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 242 dengan nilai preferensi sebesar 1.2426 dan alternatif terbaik kesepuluh terdapat pada data ke 187 dengan nilai preferensi sebesar 1.0655. Hasil nilai preferensi dari 258 alternatif berdasarkan bobot dari data set akan menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan berdasarkan bobot dari data set *User Knowledge Modelling*. Dalam menentukan akurasi, hasil akar dari jumlah kuadrat nilai preferensi 258 alternatif dikurangi jumlah nilai preferensi 258 alternatif yang dibagi dengan 258 alternatif dan dibagi dengan jumlah alternatif pada data set yaitu 258 dikurangi 1, akan menghasilkan nilai standar deviasi. Standar deviasi dapat dihitung dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 258 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set *User Knowledge Modelling* dihitung berdasarkan persamaan (2.9). Dalam pengujian data set *User*

*Knowledge Modelling* dengan jumlah alternatif sebanyak 258 data maka didapat akurasi sebesar 36.92 % yang diperoleh dari jumlah hasil nilai preferensi 258 alternatif.

Pada proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan *gain ratio* sama dengan proses pengujian metode *Simple Additive Weighting* (SAW) menggunakan pembobotan atribut berdasarkan bobot dari data set. Namun yang membedakan pada proses pengujian yaitu pada hasil nilai rating kerja ternormalisasi membentuk matriks ternormalisasi R, yang akan dikalikan dengan bobot preferensi setiap atribut berdasarkan bobot *gain ratio* pada tabel 4.16 menggunakan persamaan (2.3) sehingga menghasilkan nilai preferensi untuk 258 alternatif. Berdasarkan hasil nilai preferensi dari 258 alternatif didapat 10 alternatif terbaik. Adapun 10 alternatif terbaik data set *User Knowledge Modelling* berdasarkan pembobotan *gain ratio* dapat dilihat pada tabel 4.24.

**Tabel 4.24** Alternatif Terbaik Data Set *User Knowledge Modelling* Berdasarkan Bobot *Gain Ratio*

No.	Alternatif	Nilai Preferensi
1.	242	1.3460
2.	249	1.2879
3.	49	1.2713
4.	246	1.2685
5.	158	1.2138
6.	187	1.1906
7.	258	1.1904
8.	173	1.1845
9.	110	1.1707
10.	210	1.1627

Dari 10 alternatif terbaik pada tabel 4.24 dapat dilihat untuk peringkat alternatif terbaik pertama terdapat pada data ke 242 dengan nilai preferensi sebesar 1.3460 dan alternatif terbaik kesepuluh terdapat pada data ke 210 dengan nilai preferensi sebesar 1.1627. Hasil nilai preferensi dari 258 alternatif berdasarkan bobot *gain ratio* akan

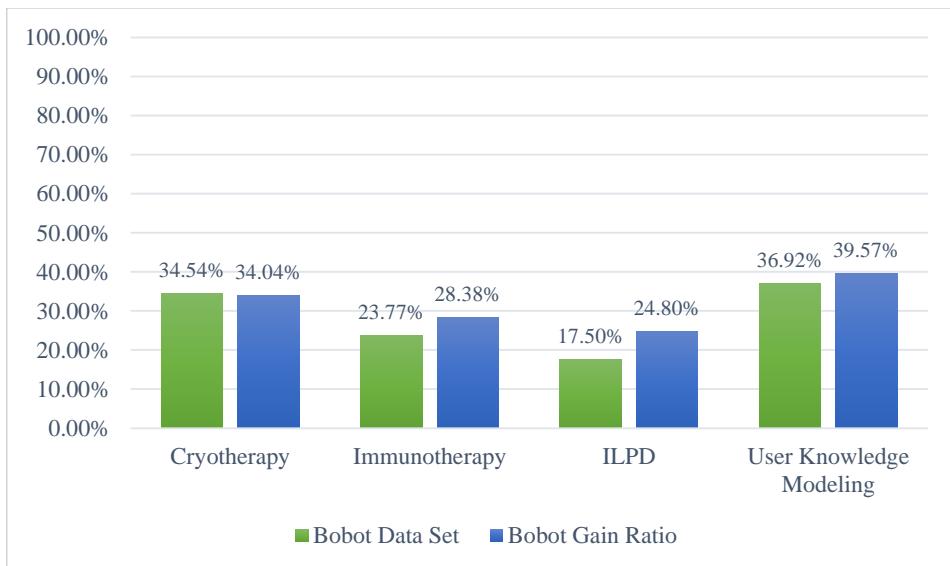
menentukan hasil akurasi dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio*. Dalam proses menentukan akurasi, sama dengan pembobotan atribut berdasarkan data set yaitu menghitung nilai standar deviasi dari 258 alternatif data dengan menggunakan persamaan (2.8). Nilai standar deviasi dikalikan dengan 100 dan dibagi dengan *mean* dari jumlah nilai preferensi 258 alternatif akan menghasilkan nilai *Relative Standard Deviation*. Nilai *Relative Standard Deviation* metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* pada data set *User Knowledge Modelling* dihitung berdasarkan persamaan (2.9). Dalam pengujian data set *User Knowledge Modelling* dengan jumlah alternatif sebanyak 258 data maka didapat akurasi sebesar 39.57 % diperoleh dari jumlah hasil nilai preferensi 258 alternatif.

#### **4.4. Analisis Hasil Pengujian**

Setelah dilakukan pengujian terhadap 4 data set dengan melalui proses perhitungan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan *gain ratio*, maka dapat dilihat hasil akurasi dalam pengambilan keputusan dan menentukan alternatif terbaik. Hasil akurasi dari data alternatif dihitung menggunakan *Relative Standard Deviation* berdasarkan persamaan (2.9). Adapun hasil pengujian dengan menggunakan pembobotan atribut berdasarkan bobot dari data set dan pembobotan atribut berdasarkan *gain ratio* terhadap pengambilan keputusan dan menentukan alternatif terbaik dapat dilihat pada tabel 4.25 dan gambar grafik 4.1.

**Tabel 4.25** Hasil Pengujian

No.	Data Set	Pengujian	Jumlah Data	Akurasi (%) Bobot Data Set	Akurasi (%) Bobot Gain Ratio
1.	<i>Cryotherapy</i>	Pengujian 1	90	34.54	34.04
2.	<i>Immunotherapy</i>	Pengujian 1	90	23.77	28.38
3.	<i>Indian Liver Patient Dataset</i>	Pengujian 1	583	17.5	24.79
4.	<i>User Knowledge Modelling</i>	Pengujian 1	258	36.92	39.57
Rata Rata				28.1825	31.6975



**Gambar 4.1** Grafik Hasil Pengujian

Setelah dilakukan pengujian terhadap 4 data set yang berbeda memiliki hasil tingkat akurasi yang berbeda. Untuk data set *Cryotherapy*, setelah dilakukan pengujian dengan 90 data alternatif berdasarkan nilai preferensi setiap alternatif menghasilkan tingkat akurasi yang berbeda yaitu, akurasi pada metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set sebesar 34.54% dan metode *Simple Additive Weighting* (SAW) dengan menggunakan

pembobotan atribut berdasarkan *gain ratio* sebesar 34.04% dan alternatif terbaik pada kedua pembobotan terdapat pada data ke 64 dengan nilai preferensi sebesar 3.0256 dengan menggunakan bobot data set dan 0.9992 dengan menggunakan bobot *gain ratio*.

Untuk data set *Immunotherapy*, setelah dilakukan pengujian dengan 90 data alternatif berdasarkan nilai preferensi setiap alternatif menghasilkan tingkat akurasi yang berbeda yaitu, akurasi pada metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set sebesar 23.77% dan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* sebesar 28.38% dan alternatif terbaik pada kedua pembobotan terdapat pada data ke 59 dengan nilai preferensi sebesar 2.3972 dengan menggunakan bobot data set dan 0.7429 dengan menggunakan bobot *gain ratio*.

Untuk data set *Indian Liver Patient Dataset* (ILPD), setelah dilakukan pengujian dengan 583 data alternatif berdasarkan nilai preferensi setiap alternatif menghasilkan tingkat akurasi yang berbeda yaitu, akurasi pada metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set sebesar 17.5% dan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* sebesar 24.79% dan alternatif terbaik pada kedua pembobotan terdapat pada data ke 136 dengan nilai preferensi sebesar 32.9878 dengan menggunakan bobot data set dan 2.6906 dengan menggunakan bobot *gain ratio*.

Untuk data set *User Knowledge Modelling* setelah dilakukan pengujian dengan 258 data alternatif berdasarkan nilai preferensi setiap alternatif menghasilkan tingkat akurasi yang berbeda yaitu, akurasi pada metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot data set sebesar 36.92 % dan metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* sebesar 39.57 % dan alternatif terbaik pada kedua pembobotan terdapat pada data ke 242 dengan nilai preferensi sebesar 1.2426 dengan menggunakan bobot data set dan 1.3460 dengan menggunakan bobot *gain ratio*.

Berdasarkan hasil pengujian terhadap 4 data set tersebut, rata rata nilai akurasi yang diperoleh berdasarkan dua pembobotan atribut yang berbeda yaitu, pembobotan atribut berdasarkan bobot data set sebesar 28.1825 % dan pembobotan atribut berdasarkan *gain*

*ratio* sebesar 31.6975 %. Maka dapat dilihat pada pembobotan atribut berdasarkan *gain ratio* memiliki akurasi yang lebih meningkat. Namun, pada data set *Cryotherapy* nilai akurasi pembobotan atribut berdasarkan *gain ratio* lebih rendah 0.5 % dibandingkan pembobotan atribut berdasarkan bobot dari data set dikarenakan tidak memiliki nilai yang sama pada satu atau suatu atribut yang berada pada kelompok data atau kelas data yang berbeda sehingga mempengaruhi hasil dari nilai preferensi alternatif.

#### 4.5. Pembahasan Hasil Analisis

Dari hasil penelitian dan pengujian yang sudah dilakukan terhadap 4 data set yang berasal dari *UCI Machine Learning Repository* menghasilkan akurasi metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan *gain ratio* yang lebih meningkat dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut berdasarkan bobot dari data set.

Pembobotan atribut berdasarkan bobot dari data set ditentukan oleh nilai kepentingan dari setiap atribut. Jika atribut memiliki nilai keuntungan atau manfaat yang besar maka semakin besar bobot semakin baik. Jika atribut memiliki nilai kerugian atau biaya yang kecil maka semakin kecil bobot semakin baik. Penentuan bobot ditentukan pengambil keputusan, sumber data dan pakar dari suatu data dan kasus.

Pembobotan berdasarkan bobot *gain ratio* ditentukan oleh jumlah data dan kelompok data yang sesuai satu sama lain pada data set. Nilai data pada setiap atribut dari seluruh alternatif tersebut memiliki pengaruh yang cukup besar dalam penentuan bobot, karena *gain ratio* menentukan bobot berdasarkan kondisi data dengan cara mengurangi bias dari data set tersebut.

Hasil pembobotan atribut berdasarkan *gain ratio* bervariasi, yaitu bobot yang dihasilkan setiap data set memiliki rentang yang berbeda beda. Rentang nilai bobot antar setiap atribut pada pembobotan berdasarkan *gain ratio* disebabkan oleh nilai pada setiap atribut yang berbeda-beda satu sama lain tanpa adanya rentang penilaian untuk setiap data maka bobot yang dihasilkan juga memiliki rentang yang berbeda-beda.

Secara umum, pembobotan atribut berdasarkan *gain ratio* memberikan hasil yang lebih baik dalam proses pengambilan keputusan menggunakan metode *Simple Additive*

*Weighting* (SAW). Rentang nilai bobot antar atribut tidak mempengaruhi kinerja metode *Simple Additive Weighting* (SAW), karena bobot setiap atribut sesuai dengan kondisi data masing-masing. Semakin tinggi bobot setiap atribut maka semakin tinggi nilai kepentingan atribut tersebut, dan memiliki pengaruh yang cukup besar dalam pengambilan keputusan. Namun demikian, validasi pembobotan atribut pada metode *Simple Additive Weighting* (SAW) sangat mempengaruhi hasil pengambilan keputusan dan menentukan alternatif terbaik. Dengan bantuan *gain ratio* dalam pembobotan atribut mampu membantu validasi dalam sistem pembobotan berdasarkan nilai dari setiap atribut. Hal tersebut dibuktikan berdasarkan tingkat akurasi rata-rata dari keempat data set meningkat sebesar 3.5150%.

## **BAB 5**

### **KESIMPULAN DAN SARAN**

#### **5.1. Kesimpulan**

Berdasarkan hasil penelitian dan pengujian metode *Simple Additive Weighting* (SAW) dapat disimpulkan bahwa dari hasil pengujian terhadap 4 data set tersebut diperoleh hasil akurasi yang berbeda. Rata rata nilai akurasi yang diperoleh berdasarkan dua pembobotan atribut yang berbeda yaitu, pembobotan atribut berdasarkan bobot data set sebesar 28.1825% dan pembobotan atribut berdasarkan *gain ratio* sebesar 31.6975 %, tingkat akurasi rata-rata dari keempat data set meningkat sebesar 3.5150%. Maka dapat dilihat akurasi kinerja pada pembobotan atribut berdasarkan *gain ratio* memiliki akurasi yang lebih meningkat.

Pembobotan atribut berdasarkan *gain ratio* memberikan hasil yang lebih baik dalam proses pengambilan keputusan menggunakan metode *Simple Additive Weighting* (SAW) dan mampu membantu validasi sistem pembobotan atribut. Variasi atau rentang dalam bobot atribut tidak mempengaruhi kinerja metode *Simple Additive Weighting* (SAW). Maka dengan adanya bantuan metode lain dalam menentukan bobot atribut dapat menghasilkan nilai akurasi dan alternatif yang lebih baik untuk pengambilan keputusan.

#### **5.2. Saran**

Adapun saran untuk penelitian selanjutnya adalah sebagai berikut :

1. Pada penelitian selanjutnya diharapkan dapat menggunakan data set yang berbeda dan bervariasi dalam pengujian, agar mengetahui tingkat akurasi dan kinerja dari metode *Simple Additive Weighting* (SAW) dengan menggunakan pembobotan atribut *gain ratio*.
2. Penelitian selanjutnya diharapkan untuk menggunakan metode pembobotan atribut yang berbeda pada metode *Simple Additive Weighting* (SAW) agar dapat meningkatkan nilai akurasi dan kinerja yang lebih baik.

## DAFTAR PUSTAKA

- Agrawal, Gaurav L. & Gupta, Prof. Hitesh. 2013. Optimization of C4.5 Decision Tree Algorithm for Data Mining Application. *International Journal of Emerging Technology and Advanced Engineering* **3**(3): 341-345. (Online) <http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.413.8487&rep=rep1&type=pdf> (17 Mei 2018).
- Annette, J. R., Banu, A. & Chandran, P. S. 2015. Comparison of Multi Criteria Decision Making Algorithms for Ranking Cloud Renderfarm Services. *Indian Journal of Science and Technology* **9**(31): 1-5. (Online) <https://arxiv.org/pdf/1611.10204.pdf> (5 Maret 2018).
- Brito, M. M. de & Evers, M. 2016. Multi-criteria decision-making for flood risk management : a survey of the current state of the art. *Natural Hazards and Earth System Sciences* **16** : 1019-1033. (Online) <https://www.nat-hazards-earth-syst-sci.net/16/1019/2016/nhess-16-1019-2016.pdf> (10 Maret 2018).
- Chou, Jyh-R. 2013. A Weighted Linear Combination Ranking Technique for Multi-Criteria Decision Analysis. *SAJEMS* (16): 28-41. (Online) <http://www.scielo.org.za/pdf/sajems/v16n5/05.pdf> (10 Maret 2018).
- Dashore, K., Pawar, S. S., Sohani, N. & Verma, D. S. 2013. Product Evaluation Using Entropy and Multi Criteria Decision Making Methods. *International Journal of Engineering Trends and Technology (IJETT)* **4**(5): 2183-2187. (Online) <http://ijettjournal.org/volume-4/issue-5/IJETT-V4I5P169.pdf> (10 Maret 2018).
- Ding, T., Liang L., Yang, M. & Wu, H. 2016. Multiple Attribute Decision Making Based on Cross-Evaluation with Uncertain Decision Parameters. *Hindawi Publishing Corporation Mathematical Problems in Engineering* **2016**: 1-10. (Online) <https://www.hindawi.com/journals/mpe/2016/4313247/> (3 April 2018).
- Dujena, A., Puyalnithi, T. 2017. Enhancing Classification Accuracy of K-Nearest Neighbours Algorithm Using Gain Ratio. *International Research Journal of Engineering and Technology (IRJET)* **4**(9): 1385-1388. (Online) <https://www.irjet.net/archives/V4/i9/IRJET-V4I9260.pdf> (3 April 2018).
- Dogan, M., Aktar, T., Toker, O. S. & Tatlisu, N. B. 2015. Combination of the Simple Additive (SAW) Approach and Mixture Design to Determine Optimum Cocoa Combination of the Hot Chocolate Beverage. *International Journal of Food Properties* **18**: 1677-1692. (Online) <https://www.tandfonline.com/doi/abs/10.1080/10942912.2014.917662> (8 Maret 2018).
- Kahraman, H. T., Sagiroglu, S. & Colak, I. 2013. Developing intuitive knowledge classifier and the modelling of domain dependent data. *Knowledge Based Systems* **37**: 283-295. (Online) <https://www.sciencedirect.com/science/article/pii/S0950705112002225> (3 Mei 2018).
- Khozeimeh, F., Alizadehsani, R., Roshanzamir, M., Khosravi, A., Layegh, P. & Nahavandi, N. 2017. An expert system for selecting wart treatment method.

- Computers in Biology and Medicine.* **81**: 167-175. (Online) <http://isiarticles.com/bundles/Article/pre/pdf/138740.pdf> (3 Mei 2018).
- Kittur, J. 2015. Optimal Generation Evaluation using SAW, WP, AHP and PROMETHEE Multi - Criteria Decision Making Techniques. *IEEE International Conference on Technological Advancements in Power & Energy* **15**: 304-309. (Online) <https://www.researchgate.net/publication/283841622> (5 Maret 2018).
- Korsemov, D. & Borissova, D. 2018. Modifications of Simple Additive Weighting and Weighted Product Models for Group Decision Making. *AMO – Advanced Modelling and Optimization* **20**(1): 101-112. (Online) <https://camo.ici.ro/journal/vol20/v20a8.pdf> (5 Maret 2018).
- Leoneti, A. B. 2016. Considerations Regarding the Choice of Ranking Multiple Criteria Decision Making Methods. *Sociedade Brasileira de Pesquisa Operacional* **36**(2): 259-277. (Online) [http://www.scielo.br/scielo.php?script=sci\\_arttext&pid=S0101-74382016000200259](http://www.scielo.br/scielo.php?script=sci_arttext&pid=S0101-74382016000200259) (8 Maret 2018).
- Mitchell, T. M. 1997. *Machine Learning*. McGraw-Hill Science: New York.
- Priyadarsini, R. P., Valarmathia, M. L., & Sivakumari, S. 2011. Gain Ratio Based Feature Selection Method for Privacy Preservation. *Ictact Journal On Soft Computing* **1**(4): 202-205. (Online) <https://pdfs.semanticscholar.org/6b29/73f809d62c2db6b915447a27c0ba7a539c48.pdf> (5 Maret 2018).
- Savitha, K. & C. Chandrasekar, Dr. 2011. Vertical Handover decision schemes using SAW and WPM for Network selection in Heterogeneous Wireless Networks. *Global Journal of Computer Science and Technology* **11**(9): 18–24. (Online) <https://arxiv.org/ftp/arxiv/papers/1109/1109.4490.pdf> (10 Maret 2018).
- Sembiring, A. P., Tulus, Sembiring, W. R., & Maulana, H. 2018. Rule Model With Fuzzy Simple Additive Weighting Approach And Weighted Product On Determination Of Position In High Education Institution. *International Journal of Latest Trends in Engineering and Technology* **10**(1): 054-062. (Online) <https://www.ijltet.org/journal/152255181610.%202197.pdf> (3 April 2018).
- Thor, J., Ding, S-H. & Kamaruddin, S. 2013. Comparison of Multi Criteria Decision Making Methods From The Maintenance Alternative Selection Perspective. *The International Journal Of Engineering And Science (IJES)* **2**(6): 27-34. (Online) [www.theijes.com/papers/v2-i6/Part.4/D0364027034.pdf](http://www.theijes.com/papers/v2-i6/Part.4/D0364027034.pdf) (5 Maret 2018).
- Velasquez, M. & Hester, P. T. 2013. An Analysis of Multi-Criteria Decision Making Methods. *International Journal of Operations Research* **10**(2): 56-66. (Online) [https://www.orstw.org.tw/ijor/vol10no2/ijor\\_vol10\\_no2\\_p56\\_p66.pdf](https://www.orstw.org.tw/ijor/vol10no2/ijor_vol10_no2_p56_p66.pdf) (5 Maret 2018).